

人工智能时代混凝土结构耐久性诊断研究进展

罗大明^{1,2}, 李 凡^{1,2}, 牛荻涛^{1,2}

(1. 西安建筑科技大学 土木工程学院, 陕西西安 710055;

2. 西安建筑科技大学 结构工程与抗震教育部重点实验室, 陕西西安 710055)

摘要:受服役环境的影响,混凝土结构普遍存在性能劣化严重、耐久性不足等问题。对在役混凝土结构进行诊断,准确识别混凝土结构损伤特征,高效评估其服役寿命,已成为保障混凝土结构服役安全的重大需求。以人工检测、传感器监测为主的诊断方法效率低下、准确性较差,难以满足实际工程结构服役安全科学诊断的要求。人工智能可为各领域研究与应用提供创新驱动力,与混凝土结构耐久性诊断技术深度融合,为混凝土结构全寿命周期的智慧运维提供新的方法。通过分析传统混凝土结构耐久性诊断技术的不足与人工智能技术的优势,从混凝土结构耐久性损伤智能感知、耐久性演化智能预测和耐久性状态智能评估等三个方面总结了人工智能在混凝土结构耐久性诊断中的应用。结果显示:人工智能技术为混凝土耐久性损伤检测与监测提供了新思路,结合传统混凝土材料损伤劣化理论,形成混凝土耐久性劣化进程与服役寿命智能预测方法,建立混凝土结构耐久性智能诊断体系,将是未来结构工程领域的重要发展方向。

关键词:混凝土结构; 深度学习; 损伤检测; 智能诊断; 寿命预测

中图分类号: TU375 **文献标志码:** A

Research progress on durability diagnosis of concrete structures based on artificial intelligence

LUO Daming^{1,2}, LI Fan^{1,2}, NIU Ditao^{1,2}

(1. School of Civil Engineering, Xi'an University of Architecture and Technology, Xi'an 710055, China;

2. Key Lab of Structural Engineering and Earthquake Resistance, Ministry of Education, Xi'an University of Architecture and Technology, Xi'an 710055, China)

Abstract: Concrete structures are often subjected to serious performance deterioration and reduced durability due to environmental influences. Diagnosis of concrete in service, accurate identification of damage characteristics of concrete structures and efficient evaluation of their service lives are important to ensure the service safety of concrete structures. The diagnosis methods based on manual detection and sensor monitoring are inefficient and inaccurate, and cannot meet the requirements of scientific diagnosis for the service safety of actual engineering structures. Artificial intelligence offers novel impetus for research and application across diverse domains, fostering deep integration with concrete structure durability diagnosis technology and furnishing fresh methodologies for intelligent operation and maintenance of concrete structures throughout their entire lifespan. The shortcomings of traditional concrete structure durability diagnosis technology and the advantages of artificial intelligence technology were discussed, and the applications of artificial intelligence in concrete structure durability diagnosis were summarized from three aspects: intelligent recognition of concrete structure durability damage, intelligent prediction of durability evolution and intelligent evaluation of durability state. The results demonstrate that artificial intelligence technology has introduced innovative approaches to detecting and monitoring concrete durability damage, with integrating conventional concrete material damage degradation theory, creating an intelligent prediction methodology for concrete durability degradation process and service life, and establishing an intelligent diagnostic system for concrete structure durability represent pivotal future directions in the field of structural engineering.

Keywords: concrete structure; deep learning; damage detection; intelligent diagnosis; life prediction

基金项目: 国家自然科学基金项目(52278217), 陕西省教育厅青年创新团队建设科研计划项目(21JJP059)。

作者简介: 罗大明, 出生于1986年, 男, 工学博士, 副教授, 主要从事混凝土及混凝土结构耐久性研究。email: dmluo@xauat.edu.cn

通信作者: 牛荻涛, 出生于1963年, 男, 工学博士, 教授, 主要从事混凝土结构耐久性与可靠性研究。email: niuditao@163.com

收稿日期: 2023年4月

0 引言

随着我国经济的迅猛发展,城镇化水平不断提升,既有建筑和基础设施存量愈来愈大。受服役环境影响,大量混凝土结构在未达到设计使用年限便产生一系列耐久性问题^[1-2]。与世界发达国家经历的大规模新建、新建与维修改造并举、以维修改造为重点的三个阶段类似,我国土木工程也逐步进入集中建造向服役运维的转型期^[3]。对在役混凝土结构进行诊断,科学感知、识别其耐久性损伤,合理评估混凝土结构耐久性并准确预测其服役寿命,对结构后续运维具有重要的理论意义和工程价值。

混凝土结构耐久性劣化机理复杂,涉及多种因素的耦合作用,对混凝土结构耐久性诊断一般先进行外观检测如目测、敲击、尺量、摄像、手工描绘等方式现场人工识别损伤,或通过实时监测结构的损伤响应获取结构的损伤状态信息,然后参照现行技术标准定性或定量评估混凝土结构的耐久性。然而,传统检测技术效率较低,时间和人工成本高,受主观因素影响较大,容易遗漏高空、内部隐蔽信息;同时,监测传感器的测点稀疏、监测信息不完备且难以与建筑结构同寿^[4],亟需更高效、更智能的混凝土结构耐久性诊断方法,实现混凝土结构的科学维护与智能运营。

从20世纪50年代人工智能概念的提出,到2006年以后深度学习(deep learning, DL)^[5]的快速发展,人工智能掀起了各个领域的研究与应用浪潮。人工智能技术与混凝土结构耐久性诊断深度融合,是推动工程结构全寿命周期智慧运维的关键。文中在传统混凝土结构耐久性诊断方法的基础上,从人工智能技术的发展及其关键技术出发,围绕混凝土耐久性损伤智能感知、耐久性演化智能预测和耐久性状态智能评估等三个方面综述人工智能在混凝土

耐久性诊断方面的应用,以期为土木工程现代化、自动化、智能化提供参考。

1 混凝土结构耐久性传统诊断方法

1.1 混凝土耐久性劣化理论

混凝土结构耐久性降低主要源于服役环境对结构的劣化作用,如海洋环境下氯离子等有害离子侵蚀引发的钢筋锈蚀^[6]、寒冷环境下冻融循环引起的混凝土开裂剥落^[7]以及一般大气环境下碳化混凝土对钢筋的保护作用降低^[8]等,如图1所示。在化工车间、海工结构、腐蚀性土壤以及使用除冰盐的道路桥梁结构中,侵蚀性离子是导致混凝土腐蚀与钢筋锈蚀的主要原因。自然腐蚀、杂散电流腐蚀、应力腐蚀和氢脆腐蚀等普遍存在,缩短了结构的使用寿命。

近些年,学者们考虑不同服役环境下的耐久性影响因素,从环境、材料、构件、结构等四个层次,围绕混凝土性能劣化和钢筋锈蚀,分析混凝土结构的耐久性破坏机理,基于损伤规律建立相应的材料性能劣化模型和结构性能退化模型,提出了多种混凝土结构服役寿命预测方法。然而,实际混凝土结构在服役过程中通常受多种因素的共同作用,结构耐久性劣化并不是各单一因素作用的简单叠加,各因素的耦合作用使结构耐久性态指标与性能之间的映射机制更为复杂。描述混凝土性能劣化的物理化学模型大多通过有限试验或工程数据简单拟合得出,对于复杂的服役环境和飞速发展的混凝土新材料并不完全适用。

1.2 混凝土结构耐久性检测手段

混凝土结构性能退化可通过裂缝、剥落、孔洞、露筋等破坏形式反映,这些损伤往往是结构失效的前兆和耐久性不足的预警。目前,对混凝土结构损伤程度的判断主要通过人工目测、尺量、摄像等方式得到结构表观损伤信息,以及超声波、雷达等技术获

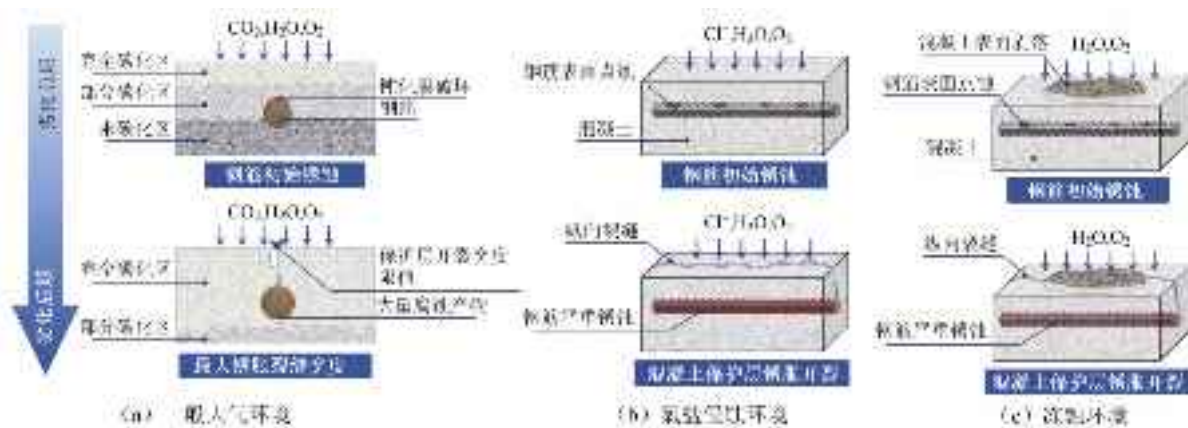


图1 混凝土耐久性劣化过程示意

Fig. 1 Schematic diagram of concrete deterioration

得结构内部损伤状况。同时,依靠基于力学和光学的传感器实时监测结构的服役状态。针对恶劣环境中的结构还需对其抗渗性、碳化(中性化)深度、侵蚀性离子含量以及钢筋锈蚀状况等进行检测完成耐久性劣化数据的采集。我国 GB/T 50784—2013《混凝土结构现场检测技术标准》^[9]中给出了不同环境下混凝土结构耐久性检测方法。然而,上述传统检测手段存在测不准、主观性强、效率低、记不全、容易造成遗漏与错误等缺点,而且往往仅根据损伤尺寸、面积等简单参数评价其对结构安全的影响,忽略了损伤与结构服役性态的关联。传统的埋入式传感器的测点稀疏且硬件难以做到与工程结构同寿,监测有效性难以验证,这些传统检测手段的瓶颈仍是目前工程结构诊治与运维方面亟待解决的问题。

1.3 混凝土结构耐久性评定方法

混凝土结构耐久性劣化过程是其材料、构件和结构性能在时间轴上的反映,各类环境侵蚀作用下材料和结构性能劣化理论是耐久性评定的基础。混凝土结构耐久性评定是结构服役安全诊断的核心,依据工程检测、监测数据,深入挖掘结构损伤响应与性能评价指标间的耦联机制,揭示混凝土材料服役性能与多维表征性态指标的映射机理,是混凝土结构耐久性评定的关键。现有的结构耐久性评定理论主要基于模糊理论^[10]、灰色理论^[11]和可靠度理论^[12]等。近年来,为完善现有工程结构鉴定与评估技术体系,我国相继颁布了 GB 50292—2015

《民用建筑可靠性鉴定标准》^[13]、GB 50144—2019《工业建筑可靠性鉴定标准》^[14]。由课题组牛荻涛教授牵头联合国内 16 家单位 40 名学者,在总结混凝土结构耐久性评估理论与方法以及工程实践经验的基础上,共同编制了 GB/T 51355—2019《既有混凝土结构耐久性评定标准》^[15],提出了基于剩余使用寿命或损伤状态的既有混凝土结构耐久性“两层次三等级”评定体系,给出了按剩余使用年限和按耐久性损伤状态的两种评定方法,为既有混凝土结构耐久性评定提供了技术支撑,其流程如图 2 所示。根据结构(或构件)耐久性裕度系数大小,可将其划分为 A(a)、B(b)、C(c)三个耐久性等级。在进行耐久性评定时,耐久性裕度系数应根据结构所处的环境类别及作用等级、结构的技术状况,并考虑耐久重要性系数 γ_0 ,按下列公式确定:

$$\xi_d = \begin{cases} t_{re}/\gamma_0 t_e & (\text{按剩余使用年限}) \\ [\Omega]/\gamma_0 \Omega & (\text{按耐久性损伤状态}) \end{cases} \quad (1)$$

式中: ξ_d 为结构耐久性裕度系数; t_e 和 t_{re} 分别为结构目标使用年限和剩余使用年限,a; $[\Omega]$ 为某项性能指标的临界值; Ω 为某项性能指标的评定值; γ_0 为耐久重要性系数,对重要结构及一般结构取 $\gamma_0 = 1.1$,对次要结构取 $\gamma_0 = 1.0$,对一般结构和次要结构,当构件容易修复、替换时取 $\gamma_0 = 0.9$ 。

然而,现行规范标准体系大多是基于成熟理论和技术手段进行保守评定,由于混凝土结构的材料性能随服役时间逐步退化,传统的评定方法还难以

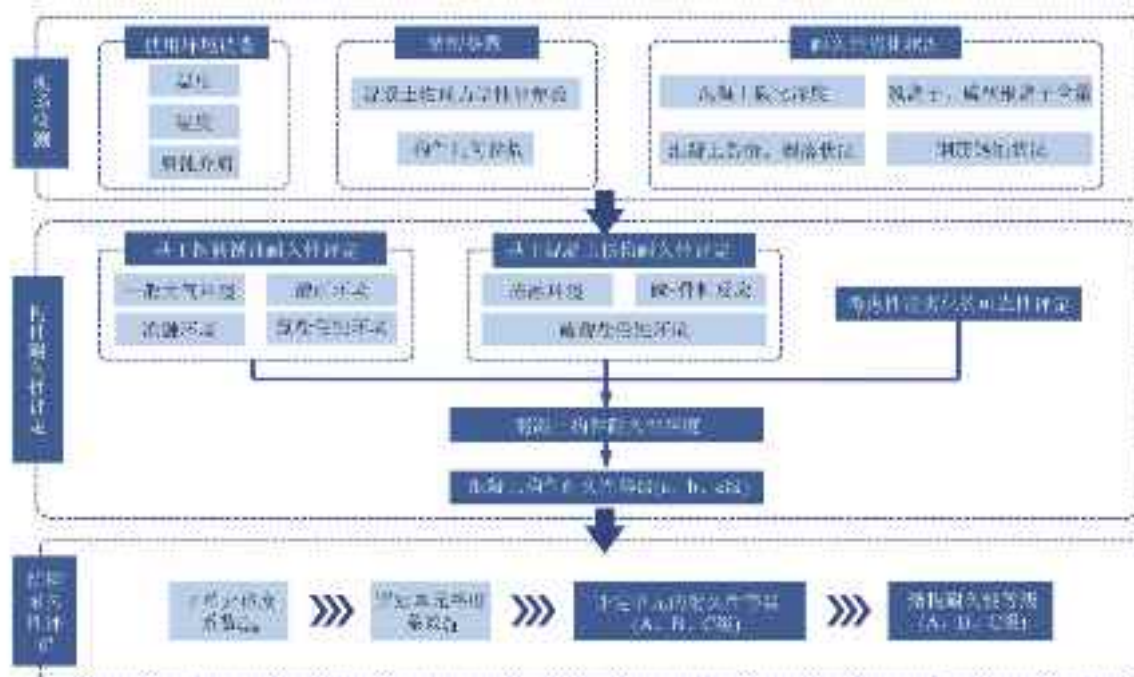


图 2 混凝土耐久性评定流程

Fig. 2 Durability evaluation process of concrete

实现对结构状况快速有效的判断。同时,混凝土结构耐久性问题复杂,对其进行评估和寿命预测需要考虑大量随机、模糊以及不完善的信息,这些信息的不确定性和难定量化的特点导致评定结果与工程实际仍存在差异。

2 混凝土结构耐久性智能诊断技术

2.1 深度学习的发展

1956 年 John McCarthy 率先在美国达特茅斯会议上提出了人工智能的概念,之后的几十年,人工智能技术先后经历了感知器、K 邻近、专家系统、Hopfield 网络、决策树、Boosting 和支持向量机等发展阶段。虽然这期间机器学习模型和优化算法不断发展,但由于计算算力与训练数据不足,人工智能技术一直处于沉寂状态。1998 年,LeCun 等^[16]提出了卷积神经网络(convolutional neural network, CNN)结构雏形 LeNet-5,推动了人工智能的发展。2006 年, Hinton 等^[17]提出深度学习算法,大大提高了神经网络的能力,开启了深度学习在学术界和工业界的新征程。随后的 10 年,各种优异的神经网络不断被提出,如 AlexNet^[18]、VGGNet^[19]、GoogLeNet^[20]、ResNet^[21]等。深度学习具有强大的特征学习和表达能力,可以捕捉高维数据并处理复杂的结构信息,在图像识别、语音识别和自然语言处理等方面已经远超过传统机器学习算法。

2.2 卷积神经网络

作为深度学习最具代表性的一种算法,卷积神经网络在计算机视觉领域,尤其是图像识别方面的发展起到了关键作用。卷积神经网络的加入,使得计算机视觉的图像识别错误率 ε 降低了近 10%,到 2015 年计算机视觉图像识别的错误率已经低于人工识别(图 3)。计算机视觉的核心是深度学习,而对于图像识别,目前最有效的工具是卷积神经网络。



图 3 计算机视觉图像识别错误率^[18-25]

Fig. 3 Error rate of computer vision image recognition^[18-25]

CNN 的体系结构是由简单模块组成的多层堆栈,其中大部分模块都需要学习,通过将输入量转换

为神经元激活的输出量,最终实现多维数据到一维特征向量的转换。典型的卷积神经网络结构包括输入层、卷积层、池化层、全连接层和输出层等,如图 4 所示。输入层的目的是接收图像,并将输入图像转换为像素矩阵供后续层的运算。卷积层是 CNN 的核心,卷积层中的单元以特征映射的形式进行运算,其中每个单元通过一组过滤器(卷积核)的权重连接到前一层特征映射中用于捕捉图像轮廓并生成各种特征响应图,如图 5 所示。池化层也称采样层,通过对特征响应图局部区域下采样以减小特征图的空间尺寸,从而降低计算的复杂程度,同时防止过拟合,常用的池化操作包括平均池化和最大池化。在经过几个卷积和池化操作之后,最终通过一个或多个全连接层将二维特征响应转化为一维特征向量,导出的向量既可以前馈到一定数量的类别中,用于分类任务,也可以作为特征向量,用于进一步处理。输出层一般位于 CNN 的末端,对于分类问题,一般采用 softmax 激活函数得到图像属于某一类别的概率。




图 4 卷积神经网络的典型结构

Fig. 4 Typical structure of convolutional neural network




图 5 卷积运算过程

Fig. 5 Process of convolution operation

对 CNN 的训练过程也称学习过程,主要通过损失函数的输出值作为反馈信号调整神经网络的参数,以提升模型对训练样本的预测能力^[18]。损失函数表示模型预测值与真实值间的差异,目前应用最广泛的损失函数为交叉熵损失函数,其表达式为

$$L = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^M p_{ic} \ln q_{ic} \quad (2)$$

式中: N 为训练样本的数量, M 为类别数; p_{ic} 为符号函数(取值 0 或 1),如果样本 i 的真实类别为 c 取 1,否则取 0; q_{ic} 为观测样本 i 属于类别 c 的预测概率。

对于训练完成的网络有效性的验证,常用准确率 A 、精确率 P 、召回率 R 以及综合评价指标 F_1 评价其性能,相应计算式为:

$$A = \frac{T_p + T_n}{T_p + T_n + F_p + F_n} \quad (3)$$

$$P = \frac{T_p}{T_p + F_p} \quad (4)$$

$$R = \frac{T_p}{T_p + F_n} \quad (5)$$

$$F_1 = \frac{2PR}{P + R} \quad (6)$$

式中: T_p 为正确识别到的正对象数; T_n 为正确识别到的负对象数; F_p 为错误识别到的正对象数; F_n 为错误识别到的负对象数。

3 混凝土结构耐久性损伤智能感知

3.1 损伤检测

近些年,各种基于视觉的方法逐渐应用于土木基础设施的损伤检测中,如基于阈值的算法^[26]、基于边缘检测的算法^[27]、基于区域的算法^[28]以及 K-means 聚类算法^[29]等。周颖等^[30]采用传统的计算机视觉技术,先将裂缝图片进行预处理,再通过连通域标记、孤立点消除、裂缝碎片拼接等图像识别方法提取裂缝骨架并计算其几何尺寸,得到了较好的识别效果。作为人工智能的一个重要分支,深度学习为图像识别和损伤检测提供了解决方案。基于深度学习的结构损伤识别方法不用预先对图像进行处理,而是通过大量数据样本以监督的方式学习和提取图像特征。根据识别任务的不同,可将深度学习算法分为图像分类、目标检测和图像分割等3类^[31],在不同任务下的混凝土裂缝识别结果如图6所示。结合无人机、机器人等搭载设备,设计对应任务的深度学习网络模型,可以实现大规模高维空间数据中结构损伤特征的检测、提取以及三维重构。国内外学者已经研究了一系列基于计算机视觉的土木工程结构智能检测技术^[32-33]。

3.1.1 损伤分类

不同服役环境下的混凝土结构耐久性破坏机理不同,由此导致结构表面出现如裂缝、剥落以及露筋锈蚀等不同类型的病害损伤。因此,为定量分析混凝土耐久性劣化程度,需要对混凝土在特定耐久性破坏因素下的损伤类型进行区分,而深度学习的图像分类算法为其提供了一种高效的手段。图像分类是根据图像信息中反映出的损伤特征,通过给每幅图片定义一个语义信息来区分不同损伤类别。该方法通常直接采用经典的卷积神经网络,结构复杂程

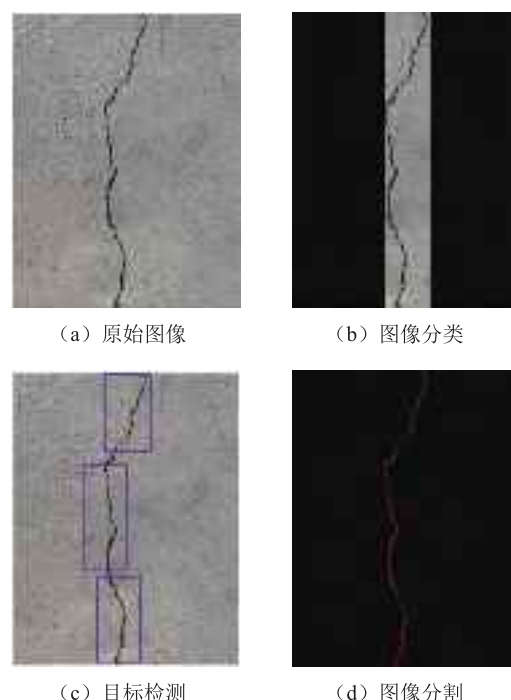


图6 基于深度学习的混凝土裂缝检测

Fig. 6 Crack detection of concrete based on deep learning

度较低,损伤检测速度较快。如王丽苹等^[34]基于原始的 AlexNet 框架,通过调整其结构层次和超参数建立了优化后的识别模型,该模型将损伤图像按照有裂缝和无裂缝分为两类,发现优化后的模型对彩色图和灰度图的识别准确率分别为 98.5% 和 98.32%。Li 等^[35]将 CNN 用于路面裂缝的检测,将识别目标分为无裂缝、纵向裂缝、横向裂缝、块状裂缝和龟裂等5类,发现该模型对每个类别的识别准确率都在94%以上。然而,基于卷积神经网络的图像分类模型往往对输入图像的尺寸大小有要求,因此可将采集到的图像裁剪划分为固定大小用于模型训练,并与滑动窗口技术相结合,实现对整个原始图像的遍历^[36]。此外,该方法目前大多仅用于混凝土裂缝的检测,而对于其他类型损伤(如冻融循环导致的混凝土剥落以及氯盐侵蚀导致的钢筋锈蚀等)识别的研究仍然缺乏。

3.1.2 损伤定位

受所处服役环境的影响,混凝土结构某些特定部位的损伤往往更严重,对这些部位的损伤检测是耐久性诊断的重点。相比图像分类,目标检测更关注结构特定损伤的位置,通过矩形框定位图像中结构损伤区域并输出分类标签,该方法主要包括以 R-CNN 为代表的候选区域算法和以 YOLO 为代表的回归算法。如 Mandal 等^[37]基于 YOLO v2 框架建立了路面裂缝的检测模型,经过 18.2 h 的训练,该模型对路面裂缝的识别精度可达 88.51%。然而,大多目标

检测模型只能识别某一种特定类型的损伤,如混凝土裂缝和钢结构裂纹等,而实际结构往往包含多种类型的病害。因此,Cha 等^[38]提出一种用于识别钢结构腐蚀、螺栓腐蚀、混凝土裂缝等 5 种损伤的检测模型,该模型由生成候选区的区域提议网络(region proposal network, RPN)和用于目标定位与分类的卷积神经网络 Fast R-CNN 组成,对 5 种损伤检测的平均精度达到 89.7%,相比基于 CNN 的检测方法,该模型具有更高的检测效率。虽然目标检测可以直接定位损伤的位置,但无法识别到损伤的几何边缘,在量化损伤尺寸参数中受到很大限制,只能通过阈值分割或边缘检测后才能进一步提取损伤骨架特征。

3.1.3 损伤提取

为诊断混凝土结构耐久性劣化程度,需要进一步提取损伤尺寸等信息,传统的图像处理技术在损伤提取方面效率较低、泛化能力较弱。图像分割算法在判别结构损伤类别的同时还能获得图像每个像素的语义信息,实现从整幅图像到目标像素端端的精细化理解与分析,目前用于图像分割最广泛的算法是全卷积神经网络(fully convolution network, FCN)以及在其基础上优化的模型,如 U-Net、Deeplab 模型等。FCN 包含用于特征提取的编码器和用于上采样的解码器,编码器在卷积神经网络的基础上通过将全连接层替换为卷积层来获取裂缝边缘的语义信息,在裂缝骨架提取中效果显著。例如:Dung^[39]和 Islam 等^[40]将 VGG 网络框架作为全卷积神经网络的编码器,基于 FCN 建立了一种检测混凝土裂缝的方法。朱苏雅等^[41]基于 U-Net 框架,搭建了一个包含 15 个卷积层的神经网络模型用于识别和提取桥梁裂缝,最后对提取到的裂缝骨架采用八方向搜索方法测量裂缝宽度,实测结果表明,该模型对裂缝提取的准确率达 90% 以上,裂缝宽度测量精度也较高。Meng^[42]将 ResNet-101 作为 U-Net 的编码器,建立了一种用于分割混凝土裂缝的神经网络 CrackNet,对比全卷积神经网络模型 FCN-8s 和 FCN-32s 的分割效果,发现 CrackNet 有更好的精度。孟诗乔等^[43]在 Deeplab 的编码器和解码器之间加入网格优化模块设计出了 Grid-Deeplab 裂缝语义分割模型,发现其在开源数据集 METU 上的识别准确率高于 U-Net 和 FCN 等模型。虽然图像分割的方法可以高效地提取出损伤的骨架特征,但此类方法的网络模型架构较为繁琐,计算量大。同时,要评定结构的劣化程度,仍需结合数字图像相关法(digital image correlation, DIC)进一步计算损伤尺寸。

基于深度学习的损伤识别方法往往需要丰富的训练数据集来保证其较好的鲁棒性。为此,Hsieh 等^[31]整理了部分用于裂缝检测的开源数据集,文中

对其进行了扩充,如表 1 所示。但目前用于混凝土结构损伤的大规模数据集仍然较少,通过人工拍摄和手动标注数据集非常耗时费力。有学者通过对原始图片进行翻转、裁剪、图像颜色对比度变换和添加随机噪声等多种变换来扩增训练样本^[44],或引入迁移学习技术进行优化^[45],将其他相关领域中预训练好的模型作为目标任务的学习起点,通过调整模型结构使其适应于目标样本的训练。近些年,利用生成对抗网络(generative adversarial networks, GANs)自动生成图像样本的方法,为解决训练数据不足的问题开辟新的思路,已有学者将其用于结构损伤检测中^[46]。

表 1 用于裂缝检测的开源数据集
Table 1 Publicly available data sets for crack detection of concrete

数据来源	数据集概况	任务
文献[47]	4 万张混凝土裂缝的彩色图像	图像分类
文献[48]	由相机拍摄的 56 000 张混凝土开裂和未开裂图像	图像分类
文献[49]	相机拍摄的 6 069 张桥梁裂缝图像	图像分类
文献[50]	智能手机拍摄获得的 9 053 张路面图像,包含 8 种损伤类型	目标检测
文献[51]	2 468 张灰度路面图像,标注 6 种损伤类型	目标检测
文献[52]	68 张带注释的路面裂缝灰度图像	图像分割
文献[53]	8 592 张多尺度多场景的结构裂缝彩色图像	图像分割
文献[54]	84 张由光学设备采集的灰度路面裂缝图像	图像分割
文献[55]	206 张含有各种裂缝的路面图像	图像分割
文献[56]	智能手机拍摄的 118 张路面裂缝图像	图像分割
文献[57]	800 张路面和混凝土墙的裂缝图像	图像分割
文献[58]	2 750 张包含混凝土裂缝、剥落、风化和孔洞四种类型损伤的图像	图像分割

3.1.4 损伤三维重构

无人机(unmanned aerial vehicle, UAV)具有自动化程度高、灵活性好等优势,在减轻人力的同时又能降低高空作业的风险。目前,将无人机与基于深度学习的计算机视觉技术相结合已经成为结构损伤检测的重要手段。搭载高分辨率相机的飞行无人机或爬机机器人能在不影响结构正常运营的情况下快速获取大量结构损伤高清图像,结合基于视觉的图像分割技术可实现结构损伤的自动识别和损伤尺寸参数的精确量化,为大跨度和高耸结构损伤的远程检测与维护提供了便捷高效的方法^[59]。无人机能较为容易地获取结构各个位置的图像,利用点云技术可以实现结构二维图像到三维模型的重构。例如:刘宇飞等^[60-61]基于无人机与三维重构技术完成了桥

墩裂缝宽度 w 的定量检测,如图 7 所示。Kim 等^[62]采用搭载高分辨率相机的无人机获取桥梁结构图像并建立点云背景模型,利用深度学习算法识别图像中的裂缝,并通过图像处理方法量化裂缝尺寸,最终将裂缝信息在点云模型中呈现。



图 7 桥墩裂缝三维点云图^[61]

Fig. 7 Three-dimensional crack contour of pier^[61]

虽然基于深度学习算法的计算机视觉技术在混凝土损伤识别中的应用已取得了较多成果,但大多仅针对裂缝进行检测。由于耐久性问题的复杂性,各种服役环境下混凝土耐久性劣化机制难以明晰,损伤类型并不局限于裂缝一种。此外,针对不同耐久性破坏因素导致混凝土产生的特定类型损伤的开源数据集仍然缺乏。因此,如何更智能、更高效地检测识别混凝土结构多种类型的耐久性损伤信息,进而深入挖掘损伤特征与性能评定指标间的耦联关系,是人工智能时代混凝土结构耐久性损伤检测下一步研究的关键。

3.2 耐久性监测

结构耐久性监测是利用传感技术模拟人体自我感知能力,通过实时监测环境荷载和结构响应获取结构全寿命服役过程中的耐久性状态信息,从而进一步研究其耐久性劣化规律并预测其剩余寿命。传统的结构耐久性监测手段主要依靠以点式分布的传感器实时感知结构损伤,易受到测点稀疏且难以与结构同寿等问题的限制。海量的监测数据是耐久性监测的一个显著特征,采用人工处理分析这些数据的效率低下。近年来,在人工智能、大数据应用背景下,众多学者开展了基于人工智能的结构耐久性监测技术研究,主要包括以材料驱动为主的智能感知技术、以视觉驱动为主的智能识别技术、以数据驱动为主的智能分析技术以及虚实结合的数字孪生技术。

3.2.1 材料驱动的智能感知

优化传感技术是结构耐久性监测的关键,而感知材料是传感技术的核心。混凝土结构由多种材料

组成,研究材料对结构耐久性损伤的自感知特性为结构耐久性监测体系的发展提供了新途径。对此,Chen 等^[63]研究发现碳纤维水泥基复合材料的电阻率与内部结构变化有一定的对应关系,提出可将其应用于结构的损伤监测。此后,国内外学者开展了自感知碳纤维水泥基复合材料研究,并取得了一定成果^[64]。随后 Li 等^[65]发现纳米水泥基复合材料的自应变感知性能,并将据此研发的传感器应用于大跨度桥梁的监测。自感知材料作为一种本征智能材料,与混凝土有天然的相容性和相同的使用寿命,与传统混凝土材料复合形成具有自感知能力的智能混凝土将为工程结构耐久性实时监测提供强有力的技术支撑。

3.2.2 视觉驱动的智能识别

机器视觉技术和深度学习算法的进步,推动了结构全寿命周期服役状态智能监测的研究。目前,已提出许多基于计算机视觉的结构动态测量和结构耐久性损伤监测方法,因其非接触、远距离、高精度、抗电磁干扰以及大范围、多目标监测等优点,已应用于桥梁耐久性长期监测的多种任务中^[66]。基于视觉驱动的结构监测系统主要由图像采集设备、计算机和处理软件组成,如图 8 所示,结合对应的计算算法,可实现结构服役过程中的性能劣化状态的获取。虽然基于视觉驱动的耐久性监测技术已得到快速发展,但目前的研究大多都是通过实验室的物理模型进行测试,而实际结构所处的服役环境复杂,视觉装置捕捉到的图像质量会受到周围环境条件的影响,研究结果能否在现场连续监测中获得较好效果仍面临着很大挑战。




图 8 视觉驱动的结构监测系统

Fig. 8 Structural monitoring system based on vision driven

3.2.3 数据驱动的智能分析

结构耐久性监测往往需要实时分析结构服役性态数据来实现结构耐久性损伤的识别,传统分析结构服役性态数据的方法主要为模型驱动方法,通过比较被测结构监测数据与有限元模型参数,修正有限元模型中的物理、几何边界条件,从而获取结构损伤程度和位置信息^[67-68]。然而,有限元模型的修正对专业性有极强的依赖且费时费力,难以适用于复

杂结构的连续监测^[69]。基于数据驱动的方法不用建立复杂的结构有限元模型,仅需充分训练神经网络,便能够分析结构行为并监测其耐久性状态。近些年,许多学者提出了结构耐久性监测数据驱动的研究方向,开展了机器学习和深度学习在该领域的研究与应用^[70-72]。

3.2.4 虚实结合的数字孪生

数字孪生技术是通过结构实体进行动态模拟,构建与结构实体具有相同属性的可视化数字模型,结合结构耐久性监测系统获取的感知数据与描述性能演变的物理模型,实现结构真实状态的仿真与监测^[73-74]。作为土木工程结构“虚实结合”智慧运维的关键技术,数字孪生为结构寿命周期耐久性态的全息智能识别与预测提供了一种新方法,但其在结构耐久性监测的研究与应用尚处于起步阶段。研究结构响应参数与耐久性劣化指标的关联机制,进一步结合数字孪生技术、仿真模型修正,以及基于计算机视觉的结构局部及整体损伤识别方法,建立全域感知、信息交互、数字联通的智能化结构监测体系,将成为未来土木工程结构智慧运维的一个重要发展方向。

4 混凝土结构耐久性演化智能预测

服役期结构性能演化与寿命预测主要取决于材料自身性能的时变退化、环境作用、荷载作用以及上述多种因素的耦合。传统用于描述结构性能演化的物理化学或经验模型,大多通过有限试验数据简单拟合得出,往往考虑因素单一,难以反映实际工程中结构性能的劣化。有的模型虽然考虑了多种因素的协同作用,但因涉及较多的参数,计算复杂不便求解,限制其在实际工程中的应用。基于时变可靠度概念的寿命预测方法目前得到广泛认可,但其准确性仍受限于系统的认知和假定。

机器学习作为一种智能算法,通过对样本的自学习便可以实现样本数据输入与输出间快速、精确的非线性映射。对此,近年来学者们开展了以人工神经网络为基础的混凝土结构耐久性预测研究,例如混凝土抗碳化性能预测^[75-76]、离子渗透性预测^[77-80]等。相比传统采用数学语言描述的显式模型,基于机器学习算法的混凝土耐久性预测模型在考虑更多影响变量的同时能够达到更高的预测精度,对现代飞速发展的混凝土材料具有良好的适用性。直观地了解模型为何会根据输入特征预测混凝土耐久性指标,对深入理解复杂环境下混凝土结构耐久性劣化机理至关重要,而机器学习算法的“黑箱”问题成为阻碍其在实际工程中应用的关键因素。

近些年,SHAP、LIME、ICE等可解释性分析方法为解释复杂的机器学习预测模型提供了有力工具,结合可视化技术可以显示各因素对耐久性预测结果的影响权重和方式,使得机器学习模型的预测和决策过程更加透明。

深度学习相比机器学习算法在处理复杂问题时有更好的泛化能力,如章玉容等^[81]采用深度学习的多层感知器(multi-layer perceptron, MLP)模型预测粉煤灰混凝土的自由氯离子浓度,结果表明,经过训练后的MLP模型预测结果具有较好的鲁棒性,预测值与实测值相符,当隐藏层层数为4层、激活函数为Relu函数时预测效果最好。Lee等^[82]提出了一种预测混凝土碳化系数和碳化深度的深度学习模型,对比实验室实测结果,对于不同的水灰比和CO₂浓度,碳化系数之间的差异在0.01~0.10 mm/a^{1/2}之间,碳化深度试验值与预测值之间有很好的相关性,如图9所示。虽然基于深度学习的智能化方法在结构服役性能演化及寿命预测方面具有较大的潜力,但模型建立对训练样本数量有较高要求,目前可以参考的研究成果较少。随着人工智能研究的快速发展,更优的算法不断被提出,因此,仍需进一步研究融合先进智能算法的结构服役性能演化与寿命预测方法。




图9 碳化深度实测值与预测值的相关性^[82]

Fig. 9 Correlation between measured and predicted carbonization depth^[82]

5 混凝土结构耐久性状态智能评估

人工智能技术的进步为结构耐久性评估带来新的驱动力,通过无监督或半监督的智能算法自主学习结构性能劣化数据特征,深入挖掘结构损伤信息,是极具潜力的混凝土耐久性智能诊断方法。例如:尚鑫等^[83]采用BP神经网络来评估混凝土斜拉桥的健康状态,并将其应用于实际工程。胡志坚等^[84]结合模糊理论和神经网络,建立了混凝土桥梁服役状态的评估系统,并验证了该系统的有效性。Michal

等^[85]利用机器学习算法建立了材料与混凝土氯离子渗透性间的映射关系,并以此来评估素混凝土和改性混凝土的抗氯离子侵蚀能力。

基于机器学习的混凝土结构耐久性评估方法较传统方法优势凸显,以服役环境数据和耐久性劣化数据作为分析样本,以神经网络算法作为分析内核,无需任何先验知识即可建立结构损伤与结构性能之间的映射关系,如图 10 所示。但其模型训练数据需求量大,依赖于特定数据集与工程场景,且所建立的纯数学模型缺乏明确的物理意义。因此,结合传统混凝土材料损伤劣化模型与人工智能驱动方法,建立新的结构安全智能诊断体系,对科学准确预测混凝土结构耐久性劣化进程、评定其服役性能具有重要的理论和工程意义。

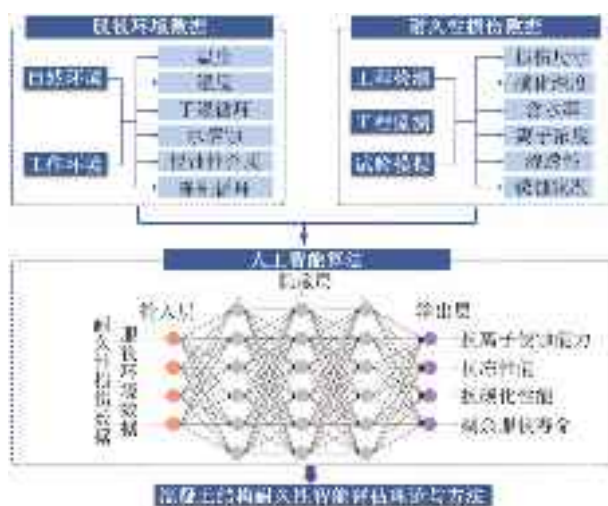


图 10 基于人工智能的服役期结构性能评定

Fig. 10 Structural performance evaluation based on artificial intelligence

6 结论与展望

1) 我国大量在役混凝土结构正步入服役中后期,由于环境作用导致其耐久性问题日益凸显。传统的损伤检测技术和耐久性评估模型在很多方面还不能满足实际混凝土结构耐久性诊断的需求。

2) 计算机视觉技术为混凝土结构损伤检测提供了新的方案,通过搭载高分辨率相机的飞行无人机或爬行机器人能在不影响结构正常运营情况下快速获取大量结构损伤图像,结合深度学习算法自主学习和识别图像特征,可以便捷、快速、准确地实现结构外观损伤分类、定位、提取以及三维重构。

3) 现有的研究大多仅从混凝土表面宏观损伤入手,利用深度学习算法识别和量化外观损伤信息,而

忽视了混凝土内部损伤特征,无法科学准确判断混凝土耐久性损伤状况。如何获取混凝土内部形态,高效识别混凝土内部细观和微观损伤信息,建立混凝土多维度损伤特征与混凝土性能劣化指标间的耦联关系仍是未来耐久性诊治领域研究的重点。

4) 自感知水泥基材料、计算机视觉以及深度学习算法的发展为结构耐久性监测提供了智能化手段,研究结构耐久性态的全域智能感知技术、智能识别技术、多元信息智能处理技术和虚实结合智能仿真模拟技术,提出结构全息智能监测的新理论与新方法,形成全域感知、信息交互、数字联通的智能化结构监测体系,将成为未来土木工程结构智慧运维的一个重要发展方向。

5) 传统描述混凝土性能劣化的物理化学模型只针对特定的试验或者工程建立,考虑因素简单,难以反映实际工程结构性能的劣化。结合传统混凝土材料损伤劣化模型与人工智能驱动方法,对科学准确模拟混凝土结构耐久性劣化进程、评定其服役性能、预测其服役寿命具有重要的理论和工程意义。

参考文献

- [1] TREVOR L, MARANDA L, JEFFERY V, et al. Durability and corrosion resistance of ultra-high performance concretes for repair[J]. Construction and Building Materials, 2022, 345(2): 128238.
- [2] 罗大明,牛荻涛,苏丽. 荷载与环境共同作用下混凝土耐久性研究进展[J]. 工程力学, 2019, 36(1): 1-14. (LUO Daming, NIU Ditao, SU Li. Research progress on durability of stressed concrete under environmental actions [J]. Engineering Mechanics, 2019, 36(1): 1-14. (in Chinese))
- [3] 刘宇飞,齐玉,李保罗,等. 工程结构运维多场景的敏感服役指标智能识别[J]. 建筑结构学报, 2022, 43(10): 1-15. (LIU Yufei, QI Yu, LI Baoluo, et al. Intelligent detection of sensitive service indicators in multiple scenarios of structural maintenance [J]. Journal of Building Structures, 2022, 43(10): 1-15. (in Chinese))
- [4] 徐阳,金晓威,李惠. 土木工程智能科学与技术研究现状及展望[J]. 建筑结构学报, 2022, 43(9): 23-35. (XU Yang, JIN Xiaowei, LI Hui. State-of-the-art and prospect of intelligent science and technology in civil engineering [J]. Journal of Building Structures, 2022, 43(9): 23-35. (in Chinese))
- [5] LECUN Y, BENGIO Y, HINTON G. Deep learning [J]. Nature, 2015, 521: 436-444.
- [6] 杨燕,谭康豪,覃英宏. 混凝土内氯离子扩散影响因素的研究综述[J]. 材料导报, 2021, 35(13): 13109-13118. (YANG Yan, TAN Kanghao, QIN Yinghong. Review of research on the influencing factors

- of chloride ion diffusion in concrete [J]. Materials Reports, 2021, 35(13): 13109-13118. (in Chinese))
- [7] 武海荣,金伟良,张锋剑,等. 关注环境作用的混凝土冻融损伤特性研究进展[J]. 土木工程学报, 2018, 51(8): 37-46. (WU Hairong, JIN Weiliang, ZHANG Fengjian, et al. A state-of-the-art review on freeze-thaw damage characteristics of concrete under environmental actions [J]. China Civil Engineering Journal, 2018, 51(8): 37-46. (in Chinese))
- [8] 韩建德,孙伟,潘钢华. 混凝土碳化反应理论模型的研究现状及展望[J]. 硅酸盐学报, 2012, 40(8): 1143-1153. (HAN Jiande, SUN Wei, PAN Ganghua. Recent development on theoretical model of carbonation reaction of concrete[J]. Journal of the Chinese Ceramic Society, 2012, 40(8): 1143-1153. (in Chinese))
- [9] 混凝土结构现场检测技术标准: GB/T 50784—2013 [S]. 北京: 中国建筑工业出版社, 2013. (Technical standard for in-situ inspection of concrete structure; GB/T 50784—2013[S]. Beijing: China Architecture & Building Press, 2013. (in Chinese))
- [10] 金伟良,王晓舟. 一种改进的混凝土桥梁耐久性评估模型[J]. 土木工程学报, 2009, 42(8): 83-90. (JIN Weiliang, WANG Xiaozhou. An improved model for assessment of the durability of existing reinforced concrete bridge[J]. China Civil Engineering Journal, 2009, 42(8): 83-90. (in Chinese))
- [11] 冯忠居,陈思晓,徐浩,等. 基于灰色系统理论的高寒盐沼泽区混凝土耐久性评估[J]. 交通运输工程学报, 2018, 18(6): 18-26. (FENG Zhongju, CHEN Sixiao, XU Hao, et al. Durability evaluation of concrete in alpine salt marsh area based on gray system theory [J]. Journal of Traffic and Transportation Engineering, 2018, 18(6): 18-26. (in Chinese))
- [12] ZHU Jinsong, GAO Change. Probabilistic durability assessment approach of deteriorating RC bridges [J]. Journal of Southeast University (English Edition), 2011, 27(1): 70-76.
- [13] 民用建筑可靠性鉴定标准: GB 50292—2015[S]. 北京: 中国建筑工业出版社, 2015. (Standard for appraisal of reliability of civil buildings; GB 50292—2015[S]. Beijing: China Architecture & Building Press, 2015. (in Chinese))
- [14] 工业建筑可靠性鉴定标准: GB 50144—2019[S]. 北京: 中国建筑工业出版社, 2019. (Standard for appraisal of reliability of industrial buildings and structures; GB 50144—2019[S]. Beijing: China Architecture & Building Press, 2019. (in Chinese))
- [15] 既有混凝土结构耐久性评定标准: GB/T 51355—2019[S]. 北京: 中国建筑工业出版社, 2019. (Standard for durability assessment of existing concrete structures; GB/T 51355—2019[S]. Beijing: China Architecture & Building Press, 2019. (in Chinese))
- [16] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition [J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [17] HINTON G E, OSINDERO S, TEH Y. A fast learning algorithm for deep belief nets[J]. Neural Computation, 2006, 18(7): 1527-1554.
- [18] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. ImageNet classification with deep convolutional neural networks[J]. Communications of the ACM, 2012, 60(6): 1097-1105.
- [19] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition [J/OL]. arXiv: 1409.1556. (2014-09-04) [2018-04-10]. <https://doi.org/10.48550/arXiv.1409.1556>.
- [20] SZEGEDY C, LIU W, JIA Y, et al. Going deeper with convolutions[C]//2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2015: 1-9.
- [21] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition [C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2015: 770-778.
- [22] RUSSAKOVSKY O, DENG J, SU H, et al. ImageNet large scale visual recognition challenge [J]. International Journal of Computer Vision, 2015, 115(3): 211-252.
- [23] SZEGEDY C, IOFFE S, VANHOUCKE V, et al. Inception-v4, Inception-ResNet and the impact of residual connections on learning[J/OL]. arXiv: 1602.07261. (2016-02-23) [2016-08-23]. <https://doi.org/10.48550/arXiv.1602.07261>.
- [24] HU J, SHEN L, ALBANIE S, et al. Squeeze-and-excitation networks [C]//2018 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2017: 7132-7141.
- [25] ZEILER M D, FERGUS R. Visualizing and understanding convolutional networks [J/OL]. arXiv: 1311.2901. (2013-11-12) [2013-11-28]. <https://doi.org/10.48550/arXiv.1311.2901>.
- [26] DINH T H, HA Q P, LA H M. Computer vision-based method for concrete crack detection [C]//2016 14th International Conference on Control, Automation, Robotics and Vision (ICARCV). New York: IEEE, 2016: 1-6.
- [27] 徐欢,李振璧,姜媛媛,等. 基于 OpenCV 和改进 Canny 算子的路面裂缝检测[J]. 计算机工程与设计, 2014, 35(12): 4254-4258. (XU Huan, LI Zhenbi, JIANG Yuanyuan, et al. Pavement crack detection based on OpenCV and improved Canny operator[J]. Computer Engineering and Design, 2014, 35(12): 4254-4258. (in Chinese))

- [28] HUANG Y, TSAI Y. Dynamic programming and connected component analysis for an enhanced pavement distress segmentation algorithm [J]. Transportation Research Record, 2011, 2225(1): 89-98.
- [29] 雷斯达,曹鸿猷,康俊涛. 基于深度学习的复杂场景下混凝土表面裂缝识别研究[J]. 公路交通科技, 2020, 37(12): 80-88. (LEI Sida, CAO Hongyou, KANG Juntao. Study on concrete surface crack recognition in complex scenario based on deep learning [J]. Journal of Highway and Transportation Research and Development, 2020, 37(12): 80-88. (in Chinese))
- [30] 周颖,刘彤. 基于计算机视觉的混凝土裂缝识别[J]. 同济大学学报(自然科学版), 2019, 47(9): 1277-1285. (ZHOU Ying, LIU Tong. Computer vision-based crack detection and measurement on concrete structure [J]. Journal of Tongji University (Natural Science), 2019, 47(9): 1277-1285. (in Chinese))
- [31] HSIEH Y, TSAI Y J. Machine learning for crack detection: review and model performance comparison [J]. Journal of Computing in Civil Engineering, 2020, 34(5): 4020031-4020038.
- [32] YEUM C M, DYKE S J. Vision-based automated crack detection for bridge inspection [J]. Computer-Aided Civil and Infrastructure Engineering, 2015, 30(10): 759-770.
- [33] 周颖,张立迅,刘彤,等. 基于计算机视觉的结构系统识别[J]. 土木工程学报, 2018, 51(11): 17-23. (ZHOU Ying, ZHANG Lixun, LIU Tong, et al. Structural system identification based on computer vision [J]. China Civil Engineering Journal, 2018, 51(11): 17-23. (in Chinese))
- [34] 王丽苹,高瑞贞,张京军,等. 基于卷积神经网络的混凝土路面裂缝检测[J]. 计算机科学, 2019, 46(增刊2): 584-589. (WANG Liping, GAO Ruizhen, ZHANG Jingjun, et al. Crack detection of concrete pavement based on convolutional neural network [J]. Computer Science, 2019, 46(Suppl. 2): 584-589. (in Chinese))
- [35] LI B, WANG K C P, ZHANG A, et al. Automatic classification of pavement crack using deep convolutional neural network [J]. The International Journal of Pavement Engineering, 2020, 21(3/4): 457-463.
- [36] CHA Y, CHOI W, BÜYÜKÖZTÜRK O. Deep learning-based crack damage detection using convolutional neural networks [J]. Computer-Aided Civil and Infrastructure Engineering, 2017, 32(5): 361-378.
- [37] MANDAL V, UONG L, ADU-GYAMFI Y. Automated road crack detection using deep convolutional neural networks[C]//2018 IEEE International Conference on Big Data. NewYork: IEEE, 2018: 5212-5215.
- [38] CHA Y J, CHOI W, SUH G, et al. Autonomous structural visual inspection using region-based deep learning for detecting multiple damage types [J]. Computer-Aided Civil and Infrastructure Engineering, 2018, 33(9): 731-747.
- [39] DUNG C V. Autonomous concrete crack detection using deep fully convolutional neural network[J]. Automation in Construction, 2019, 99: 52-58.
- [40] ISLAM M M M, KIM J. Vision-based autonomous crack detection of concrete structures using a fully convolutional encoder-decoder network [J]. Sensors, 2019, 19(19): 4251.
- [41] 朱苏雅,杜建超,李云松,等. 采用 U-Net 卷积网络的桥梁裂缝检测方法[J]. 西安电子科技大学学报, 2019, 46(4): 35-42. (ZHU Suya, DU Jianchao, LI Yunsong, et al. Method for bridge crack detection based on the U-Net convolutional networks[J]. Journal of Xidian University, 2019, 46(4): 35-42. (in Chinese))
- [42] MENG X. Concrete crack detection algorithm based on deep residual neural networks [J]. Scientific Programming, 2021, 2021(3): 1-7.
- [43] 孟诗乔,张啸天,乔甦阳,等. 基于深度学习的网格优化裂缝检测模型研究[J]. 建筑结构学报, 2020, 41(增刊2): 404-410. (MENG Shijiao, ZHANG Xiaotian, QIAO Suyang, et al. Research on grid optimized crack detection model based on deep learning [J]. Journal of Building Structures, 2020, 41(Suppl. 2): 404-410. (in Chinese))
- [44] 黄彩萍,甘书宽,谭金甲,等. 基于深度学习的混凝土表观病害智能分类器[J]. 华中科技大学学报(自然科学版), 2021, 49(4): 96-101. (HUANG Caiping, GAN Shukuan, TAN Jinjia, et al. Intelligent classifier of concrete apparent diseases based on deep learning[J]. Journal of Huazhong University of Science and Technology (Natural Science Edition), 2021, 49(4): 96-101. (in Chinese))
- [45] KIM B, CHO S. Automated vision-based detection of cracks on concrete surfaces using a deep learning technique[J]. Sensors, 2018, 18(10): 3452-3469.
- [46] ZHANG G, CUI K, HUNG T, et al. Defect-GAN: high-fidelity defect synthesis for automated defect inspection [C]//2021 IEEE Winter Conference on Applications of Computer Vision (WACV). NewYork: IEEE, 2021: 2524-2534.
- [47] SORGUC A G, OZGENEL C F. Performance comparison of pretrained convolutional neural networks on crack detection in buildings[C]//35th International Symposium on Automation and Robotics in Construction (ISARC). Berlin: ISARC, 2018: 693-700.
- [48] DORAFSHAN S, THOMAS R J, MAGUIRE M.

- SDNET2018: an annotated image dataset for non-contact concrete crack detection using deep convolutional neural networks[J]. *Data in Brief*, 2018, 21(6): 1664-1668.
- [49] XU H, SU X, WANG Y, et al. Automatic bridge crack detection using a convolutional neural network [J]. *Applied Sciences*, 2019, 9(14): 2867-2880.
- [50] MAEDA H, SEKIMOTO Y, SETO T, et al. Road damage detection and classification using deep neural networks with smartphone images[J]. *Computer-Aided Civil and Infrastructure Engineering*, 2018, 33(12): 1127-1141.
- [51] EISENBACH M, STRICKER R, SEICHTER D, et al. How to get pavement distress detection ready for deep learning? A systematic approach [C]//2017 International Joint Conference on Neural Networks (IJCNN). New York: IEEE, 2017: 2039-2047.
- [52] AMHAZ R, CHAMBON S, IDIER J, et al. Automatic crack detection on two-dimensional pavement images: an algorithm based on minimal path selection[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2016, 17(10): 2718-2729.
- [53] LIU Y, YAO J, LU X, et al. DeepCrack: a deep hierarchical feature learning architecture for crack segmentation [J]. *Neurocomputing*, 2019, 338: 139-153.
- [54] OLIVEIRA H, CORREIA P L. CrackIT: an image processing toolbox for crack detection and characterization [C]//2014 IEEE International Conference on Image Processing (ICIP). New York: IEEE, 2014: 798-802.
- [55] ZOU Q, CAO Y, LI Q, et al. CrackTree: automatic crack detection from pavement images [J]. *Pattern Recognition Letters*, 2012, 33(3): 227-238.
- [56] SHI Y, CUI L, QI Z, et al. Automatic road crack detection using random structured forests [J]. *IEEE Transactions on Intelligent Transportation Systems*, 2016, 17(12): 3434-3445.
- [57] YANG X, LI H, YU Y, et al. Automatic pixel-level crack detection and measurement using fully convolutional network [J]. *Computer-Aided Civil and Infrastructure Engineering*, 2018, 33(12): 1090-1109.
- [58] LI S, ZHAO X, ZHOU G. Automatic pixel-level multiple damage detection of concrete structure using fully convolutional network[J]. *Computer-Aided Civil and Infrastructure Engineering*, 2019, 34(7): 616-634.
- [59] WANG H, ZHAI L, HUANG H, et al. Measurement for cracks at the bottom of bridges based on tethered creeping unmanned aerial vehicle[J]. *Automation in Construction*, 2020, 119: 103330-103342.
- [60] 刘宇飞,樊健生,聂建国,等. 结构表面裂缝数字图像法识别研究综述与前景展望[J]. *土木工程学报*, 2021, 54(6): 79-98. (LIU Yufei, FAN Jiansheng, NIE Jianguo, et al. Review and prospect of digital-image-based crack detection of structure surface [J]. *China Civil Engineering Journal*, 2021, 54(6): 79-98. (in Chinese))
- [61] LIU Y, NIE X, FAN J, et al. Image-based crack assessment of bridge piers using unmanned aerial vehicles and three-dimensional scene reconstruction [J]. *Computer-Aided Civil and Infrastructure Engineering*, 2020, 35(5): 511-529.
- [62] KIM I, JEON H, BAEK S, et al. Application of crack identification techniques for an aging concrete bridge inspection using an unmanned aerial vehicle [J]. *Sensors*, 2018, 18(6): 1811.
- [63] CHEN P, CHUNG D D L. Carbon-fiber-reinforced concrete as an intrinsically smart concrete for damage assessment during dynamic loading[J]. *ACI Materials Journal*, 1996, 93(4): 341-350.
- [64] SUN M, LIU Q. A study of piezoelectric properties of carbon fiber reinforced concrete and plain cement paste during dynamic loading [J]. *Cement and Concrete Research*, 2000, 30(10): 1593-1595.
- [65] LI H, XIAO H, OU J. A study on mechanical and pressure-sensitive properties of cement mortar with nanophase materials [J]. *Cement and Concrete Research*, 2004, 34(3): 435-438.
- [66] REAGAN D, SABATO A, NIEZRECKI C. Feasibility of using digital image correlation for unmanned aerial vehicle structural health monitoring of bridges [J]. *Structural Health Monitoring*, 2017, 17(5): 1056-1072.
- [67] FANG S. Damage detection of long-span bridge structures based on response surface model [J]. *Thermal Science*, 2020, 24(3): 1497-1504.
- [68] 翁顺,朱宏平. 基于有限元模型修正的土木结构损伤识别方法[J]. *工程力学*, 2021, 38(3): 1-16. (WENG Shun, ZHU Hongping. Damage identification civil structures based on finite element model updating [J]. *Engineering Mechanics*, 2021, 38(3): 1-16. (in Chinese))
- [69] 王凌波,王秋玲,朱钊,等. 桥梁健康监测技术研究现状及展望[J]. *中国公路学报*, 2021, 34(12): 25-45. (WANG Lingbo, WANG Qiuling, ZHU Zhao, et al. Current status prospects of research on bridge health monitoring technology [J]. *China Journal of Highway and Transport*, 2021, 34(12): 25-45. (in Chinese))
- [70] 包龙生,曹悦,赵宁,等. BP神经网络和曲率模态理论在桥梁损伤识别中的应用[J]. *沈阳建筑大学学报(自然科学版)*, 2021, 37(2): 296-302. (BAO

- Longsheng, CAO Yue, ZHAO Ning, et al. Application of BP neural network and curvature mode theory in bridge damage identification[J]. Journal of Shenyang Jianzhu University (Natural Science), 2021, 37 (2): 296-302. (in Chinese)
- [71] NEVES A C, GONZÁLEZ I, KAROUMI R, et al. The influence of frequency content on the performance of artificial neural network-based damage detection systems tested on numerical and experimental bridge data[J]. Structural Health Monitoring, 2020, 20 (3): 1331-1347.
- [72] BAO Y, CHEN Z, WEI S, et al. The state of the art of data science and engineering in structural health monitoring[J]. Engineering, 2019, 5(2): 234-242.
- [73] SHIM C, DANG N, LON S, et al. Development of a bridge maintenance system for prestressed concrete bridges using 3D digital twin model[J]. Structure and Infrastructure Engineering, 2019, 15 (10/12): 1319-1332.
- [74] LU R, BRILAKIS I. Digital twinning of existing reinforced concrete bridges from labelled point clusters [J]. Automation in Construction, 2019, 105: 102831-102837.
- [75] TAFSESE W Z, SISTONEN E, PUTTONEN J. CaPrM: carbonation prediction model for reinforced concrete using machine learning methods [J]. Construction and Building Materials, 2015, 100: 70-82.
- [76] 高攀祥,于军琪,牛荻涛,等. 神经网络在混凝土碳化深度预测中的研究应用[J]. 计算机工程与应用, 2014(14): 238-241. (GAO Panxiang, YU Junqi, NIU Ditao, et al. Research and application on neural network in concrete carbonation depth prediction[J]. Computer Engineering and Applications, 2014 (14): 238-241. (in Chinese))
- [77] PARICHATPRECHA R, NIMITYONGSKUL P. Analysis of durability of high performance concrete using artificial neural networks[J]. Construction and Building Materials, 2009, 23(2): 910-917.
- [78] DELNAVAZ A, RAMEZANIANPOUR A A. The assessment of carbonation effect on chloride diffusion in concrete based on artificial neural network model[J]. Magazine of Concrete Research, 2012, 64 (10): 877-884.
- [79] KHAN M I. Predicting properties of high performance concrete containing composite cementitious materials using artificial neural networks [J]. Automation in Construction, 2012, 22: 516-524.
- [80] LIU Q F, LQBAL M F, YANG J, et al. Prediction of chloride diffusivity in concrete using artificial neural network: modelling and performance evaluation [J]. Construction and Building Materials, 2020, 268: 121082-121101.
- [81] 章玉容,余威龙,麻雪晴,等. 基于深度学习的粉煤灰混凝土氯离子浓度预测[J]. 北京工业大学学报, 2023, 49 (2): 205-212. (ZHANG Yurong, YU Weilong, MA Xueqing, et al. Prediction of chloride concentration in fly ash concrete based on deep learning [J]. Journal of Beijing University of Technology, 2023, 49(2): 205-212. (in Chinese))
- [82] LEE H, LEE H S, SURANENI P. Evaluation of carbonation progress using AIJ model, FEM analysis, and machine learning algorithms[J]. Construction and Building Materials, 2020, 259: 119703-119709.
- [83] 尚鑫,徐岳,马保林,等. 基于神经网络的混凝土斜拉桥健康状态评估[J]. 武汉理工大学学报, 2011, 33(8): 79-83. (SHANG Xin, XU Yue, MA Baolin, et al. Health condition assessment of concrete cable-stayed bridge based on ANN[J]. Journal of Wuhan University of Technology, 2011, 33 (8): 79-83. (in Chinese))
- [84] 胡志坚,常英,乐云祥,等. 基于模糊神经网络的混凝土桥梁状态评估系统研究[J]. 桥梁建设, 2009 (1): 19-21. (HU Zhijian, CHANG Ying, LE Yunxiang, et al. Research of a condition state assessment system for concrete bridges based on fuzzy-neural network [J]. Bridge Construction, 2009 (1): 19-21. (in Chinese))
- [85] MICHAL M, MICHAL A G, KAROLINA G. Prediction of the chloride resistance of concrete modified with high calcium fly ash using machine learning[J]. Materials, 2015, 8(12): 8714-8727.