

文章编号:1001-7372(2023)02-0001-21

基于深度学习的土木基础设施裂缝检测综述

邓 露^{1,2}, 褚鸿鹄², 龙砾芝², 王 维^{*1,2}, 孔 焰^{1,2}, 曹 然^{1,2}

(1. 湖南大学 工程结构损伤诊断湖南省重点实验室,湖南 长沙 410082;

2. 湖南大学 土木工程学院,湖南 长沙 410082)

摘要: 基于深度学习的裂缝检测对于降低基础设施运营风险、节约运维成本并推进中国土木工程行业智能化转型具有重要意义。算法、数据集和评价指标是构建深度学习裂缝检测模型的关键要素;裂缝检测模型集成于机器人平台,从而实现对土木基础设施的全自动裂缝检测。为此,从以上4个方面对当前研究进行了系统梳理。首先,回顾了深度学习的发展历程,重点介绍了深度卷积神经网络在计算机视觉领域的应用及其在图像处理方面较传统算法所具有的显著优势。接着,详细介绍了3类基于深度学习的裂缝检测主流算法,包括分类算法、目标检测算法和语义分割算法。然后,对现有裂缝图像数据集以及模型性能评价指标进行了归纳。最后,总结了土木基础设施的各类裂缝检测机器人平台。综合分析表明:基于卷积神经网络主干结构的深度学习算法已被广泛用于土木基础设施表面裂缝的精准定位与分类,而裂缝的尺寸信息仍需依靠传统图像处理技术进行提取;由于像素级标注的成本和专业性高,大型的裂缝语义分割数据集相对缺乏,致使当前基于语义分割算法的裂缝检测模型鲁棒性较差;目前多数研究人员采用个人建立的裂缝数据集进行模型训练且采用不同的指标进行模型性能评价,缺乏统一的基准测试数据集和评价指标体系,无法对不同模型的性能进行平行比较;目前针对不同基础设施已相应开发了一些裂缝检测机器人,提高裂缝检测机器人的多场景适应性,并降低其应用成本是未来的发展方向。

关键词: 桥梁工程;基础设施裂缝检测;综述;深度学习;计算机视觉

中图分类号:U443

文献标志码:A

Review of Deep Learning-based Crack Detection for Civil Infrastructures

DENG Lu^{1,2}, CHU Hong-hu², LONG Li-zhi², WANG Wei^{*1,2},
KONG Xuan^{1,2}, CAO Ran^{1,2}

(1. Hunan Provincial Key Laboratory for Damage Diagnosis of Engineering Structures, Hunan University,
Changsha 410082, Hunan, China; 2. College of Civil Engineering, Hunan University,
Changsha 410082, Hunan, China)

Abstract: Crack detection using deep learning (DL) is important for reducing infrastructure operation risks, saving operation and maintenance costs, and promoting the intelligent transformation of the civil engineering industry. In current practice, algorithms, datasets, and evaluation metrics are the key components of DL-based crack detection. Hence, in this article, four aspects of current research are reviewed systematically. First, the development of the DL

收稿日期:2021-09-14

基金项目:国家自然科学基金项目(52278177);国家自然科学基金青年科学基金项目(51808209);

湖南省科技创新领军人才项目(2021RC4025);湖南省研究生科研创新项目(QL20210106)

作者简介:邓 露(1984-),男,湖南双峰人,教授,博士研究生导师,工学博士,E-mail:denglu@hnu.edu.cn。

*通讯作者:王 维(1988-),男,湖南邵阳人,副教授,工学博士,E-mail:wang_wei@hnu.edu.cn。

method is reviewed, and the applications of deep convolution neural networks in the field of computer vision and their significant advantages over conventional algorithms in image data processing are introduced. Second, three popular DL algorithms for crack detection are described in detail. Third, the available crack image datasets and current evaluation metrics are reviewed. Finally, recent research outcomes in this field are summarized, and future research needs are discussed. The comprehensive analyses show that, based on the backbone of convolutional neural networks, DL algorithms have been widely used to locate and classify cracks on the surface of civil infrastructure with good accuracy, although obtaining quantitative information about cracks still requires auxiliary extraction using traditional image-processing technology. Because of the high cost and technical skills required for pixel-level annotation, there is a lack of large-scale crack semantic segmentation datasets, resulting in crack detection models with poor robustness. Moreover, most researchers created their own datasets for model training and used different metrics to evaluate their model performance, highlighting the need to establish a benchmark dataset for model training and use a set of popular indices to compare the performances of different models. Crack detection robots have been developed for different types of infrastructure, and it is the development trend to improve multiscene adaptability and reduce the application cost of crack detection robots.

Keywords: bridge engineering; crack detection of infrastructures; review; deep learning; computer vision

Received 14 Sept. 2021

Funding: National Natural Science Foundation of China (52278177); National Natural Science Foundation of China Youth Project (51808209); Hunan Provincial Science and Technology Innovation Leader Project (2021RC4025); Hunan Provincial Innovation Foundation for Postgraduate (QL20210106)

*Corresponding author. *E-mail address:* wang_wei@hnu.edu.cn.

<https://doi.org/10.19721/j.cnki.1001-7372.2023.02.001>

0 引言

土木基础设施是保障国家经济长期稳定发展的有力支撑,对其进行定期检查和维护对预防灾难性事故至关重要^[1]。专业管养团队开展的人工目视检查一直以来都是运营期内基础设施状态评估所依靠的最为直观的手段之一^[2-5],但是完全基于肉眼进行的传统人工目视检查往往存在耗时、主观、危险等问题。为提高土木基础设施检测的效率和鲁棒性,现阶段许多学者在传统检测手段的基础上深度融合计算机视觉前沿技术,围绕智能化检测手段展开了系列研究。其中裂缝的自动化检测是土木基础设施智能检测领域的一个重要分支^[6-7]。受限于建筑材料自身性能,大部分基础设施在服役期内都处于带裂缝工作状态^[8-10],而部分基础设施因所处相对恶劣的工作环境以及承受日趋增大的荷载作用,裂缝的萌生和发展迅速,导致其使用寿命大幅缩短甚至直

接诱发严重安全事故^[11]。

土木基础设施裂缝的种类繁多且数量庞大,裂缝根据其成因、尺寸和形状等信息可分为多类,不同类别的裂缝对结构安全的影响程度不一^[6],利用传统人工方法对这些裂缝进行逐一筛查在效率和成本方面都存在巨大挑战。如何从海量的裂缝中准确识别出可能对结构安全性能造成影响的裂缝是当前管养部门最为关心的问题之一。

近年来,基于计算机视觉的结构裂缝检测技术迅速发展。已有大量学者采用基于特征的机器学习方法和传统图像处理技术对结构裂缝进行提取和分析^[6-7,12-13]。由于现实中的裂缝往往存在于复杂多变的环境条件中,在检测过程中利用上述视觉方法获取的裂缝检测数据常包含大量噪声,这将严重影响检测结果的可使用性^[14]。因此,面向技术现状及行业需求,研发高精度、高鲁棒性的裂缝检测方法已成为科学界和工程界共同关注的问题。深度学习作

为人工智能领域的重要分支,是一种顶层计算逻辑贴合人类决策过程的智能化方法,已在语音识别、文本翻译、图像处理等多个领域展现出了传统方法所不具备的优势^[15]。特别是在医学影像分析相关任务中,深度学习方法已被用于辅助医生从海量医学影像中深入挖掘有效病理信息,其在疾病智能诊断、智能临床决策以及治疗预后等方面取得了显著的成果^[16]。受此启发,部分学者将深度学习方法引入裂缝视觉检测领域,用以取代传统图像处理技术和基于特征的机器学习技术,实现多场景下土木基础设施裂缝的高精度检测^[17]。此外,近年来高性能图形计算单元(Graphics Processing Unit, GPU)迅速发展,进一步推动了基于深度学习的裂缝检测算法的开发与部署。但与此同时,基于深度学习的视觉检测方法也存在一系列关键技术难题,阻碍其在工程实际中的推广与应用^[1]。为此,土木工程领域研究人员结合本学科自身特点,开展了跨行业、跨领域及跨专业的多学科深度合作,以建立适合本行业的人工智能理论体系,并进一步将基于深度学习的裂缝检测算法与先进传感设备、高清成像系统、轻量化载体机器人等现代科技相结合,实现裂缝智能化检测,为基础设施的养护维修科学决策提供了有效支撑^[18-20]。

本文主要总结了近年来基于深度学习的裂缝检测技术的研究成果及其应用情况。首先结合深度学习的发展历程,对卷积神经网络及其在计算机视觉领域中的优异表现进行了介绍,之后主要从深度学习框架、深度学习算法、深度学习数据集、评价指标及机器人平台等方面,综述了目前基于深度学习进行裂缝检测的研究进展,最后总结了现有方法的优势与不足,并对土木基础设施裂缝智能化检测的发展趋势进行了分析与展望。

1 深度学习的发展历程

本节主要回顾深度学习的发展历程,重点介绍卷积神经网络的基本架构及其在计算机视觉领域所表现出的传统方法所不可替代的优势。

1.1 深度学习的诞生、衰落和兴起

深度学习是机器学习的一个分支,是一种基于设计好的深度神经网络学习样本数据内在规律和表示层次的类脑运算方法。深度学习模型可被直观地理解为具有深层结构的人工神经网络。初期设计的浅层人工神经网络是深度学习模型的基础,其起源最早可追溯到 20 世纪 40 年代^[21]。人工神经网络最初被开发的目的是用于模拟人脑系统,以符合人

类大脑顶层计算逻辑为原则对实际问题进行决策^[22]。在 20 世纪八九十年代,随着 Rumelhart 和 Hinton 等^[23]使用了 BP(Back Propagation)算法学习分布式表征,神经网络开始逐渐被应用于学术研究。然而,受限于当时计算设备运算能力有限、数据不足以及训练过程中梯度消失等诸多问题,人工神经网络还未待其潜能被充分挖掘就于上世纪末逐渐淡出了人们的视野。

2006 年, Hinton 与 Salakhutdinov^[24]为“梯度消失”问题提供了有效的解决方案,继而正式提出深度学习的概念,在学术界和工业界引起了巨大反响。Hinton 等^[25]于 2012 年利用深度学习在语音识别领域取得了开创性成果,证明了深度学习的强大功能。当前深度学习应用如此广泛的原因主要可归纳为以下几点:

(1) 网络结构和训练模式的改进^[26]。例如利用自编码器或严格的玻尔兹曼机结构对深度学习模型进行无监督的分层预训练,可提供良好的初始化效果^[27-28]; dropout 结构的引入有效避免了训练中的过拟合问题^[26,29]; 利用批处理规范化,使深层网络的训练变得非常有效^[30]。

(2) 高性能并行计算系统和相关硬件的开发^[31],例如 Nvidia GPU 集群。

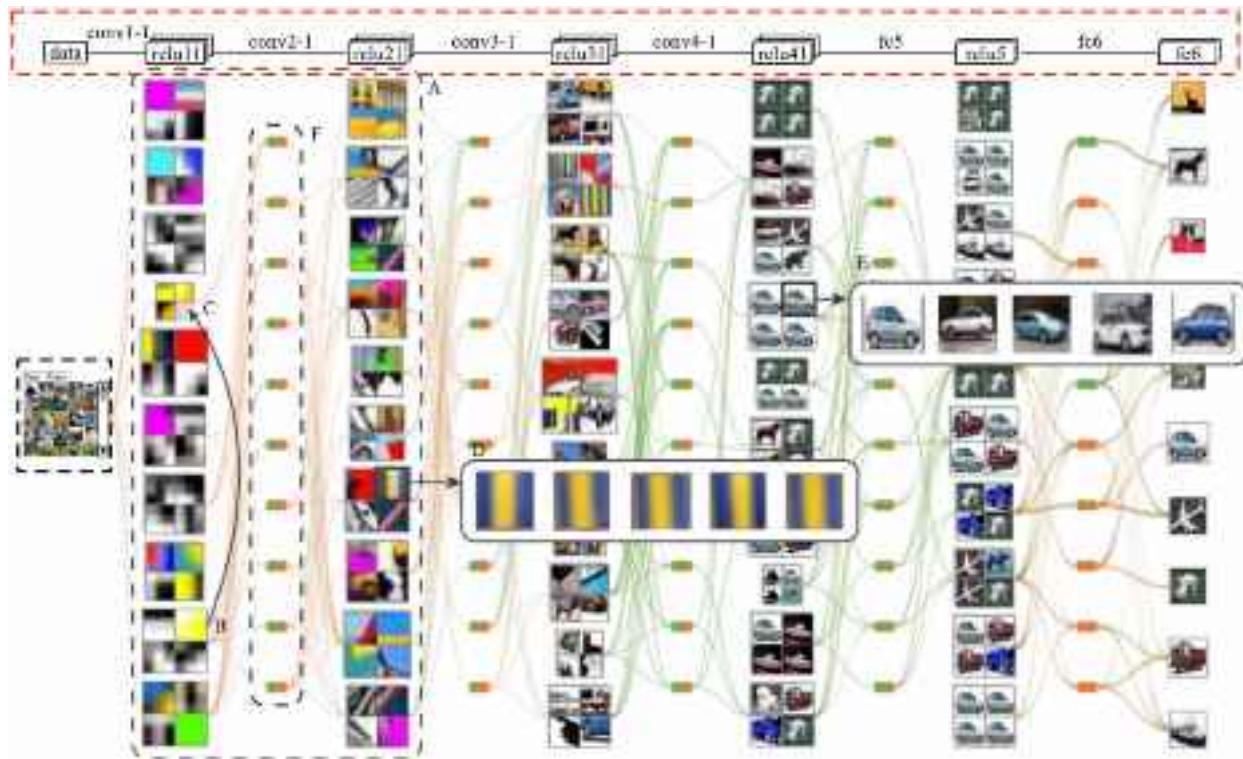
(3) 大量带标注的开源数据集的出现,提高了模型检测性能的下限^[31],例如 ImageNet^[32]、MS COCO^[33] 和 Pascal VOC^[34]。

深度学习极大地促进了产业智能化发展,并被越来越多相关领域研究人员和机构投入使用,已在智能交通、音频处理、自然语言处理、机器人技术、生物信息学、医学、电子游戏、搜索引擎、在线广告和金融等多个领域展现出常规技术所不具备的优势^[35]。

1.2 卷积神经网络

卷积神经网络 (Convolutional Neural Networks, CNN) 作为一种前馈神经网络,是深度学习中最具代表性的算法之一。基于卷积核滑动运算的特性并结合改进的神经网络算法,CNN 可以模拟人脑视觉皮层复杂的层次化认知规律,有效捕捉图形的网格状拓扑结构。CNN 在计算机视觉领域,尤其是在图像数据处理方面有着常规算法所不具备的优势,是目前基于图像的裂缝检测方法最为常用的网络结构。

标准的 CNN 包含卷积层、池化层、激活函数层和全连接层,图 1 对一个标准卷积神经网络在大型公开数据集上的运算过程进行了可视化^[36]。卷积

图1 标准卷积神经网络在大型公开数据集上的运算过程^[36]Fig. 1 Operation Process of Standard Convolutional Neural Networks on a Public Dataset^[36]

层是CNN的核心,用于特征提取。根据所设计的卷积核,卷积运算可以捕捉图像轮廓并生成相应的特征图。池化层通过采样邻域范围内最大值或平均值执行下采样操作,减小特征图的空间尺寸。激活函数层利用激活函数对输入数据进行剔除,最常用的激活函数包括ReLU函数以及相关演变函数^[37]。全连接层中的神经元完全连接到其上一层中所有被激活的神经元。训练CNN时,模型会对预测图像的类别进行打分,使用选定的损失函数计算训练损失,最后通过反向传播算法以及梯度下降来更新权重^[38]。交叉熵损失是使用最广泛的损失函数之一,随机梯度下降是处理梯度下降最流行的方法^[39]。表1总结了当前典型的CNN主干结构。深度学习框架、算法以及数据集是训练深度学习裂缝检测模型的三大要素,后文将按照图2所示流程,对基于深度学习的裂缝检测技术进行系统总结。

2 深度学习框架

深度学习框架提供了一种通过预构组件进行目标模型快速搭建的方法。在深度学习发展初期,研究人员几乎对任一新项目都需要编写海量代码,而深度学习项目搭建流程大同小异,不同项目代码中实际上存在大量重复的基础性工作。为提高项目搭

表1 典型卷积神经网络架构汇总

Table 1 Summary of Typical Architectures of Deep Convolution Neural Networks

网络名称	年份/ ILSVRC 排名	Top-5 错误 率/%	参数总数
LeNet ^[40]	1998/		60 000
AlexNet ^[26]	2012/第1名	16.4	60 000 000
ZFNet ^[41]	2013/第1名	11.7	
VGG Net ^[42]	2014/第2名	7.3	138 000 000
GoogleNet ^[43]	2015/第1名	6.7	V1: 5 000 000 V2: 23 000 000
ResNet-50 ^[44]	2016/第1名	3.57	25 600 000
DenseNet-100 ^[45]	2017/		6 980 000
Shufflenet ^[46]	2017/	7.8*	
EfficientNet-B7 ^[47]	2019/第1名	3.0	66 000 000
GhostNet(s=2) ^[48]	2020/第1名	7.7	13 000 000

注: * 表示数据为 Top-1 错误率; ILSVRC 表示 ImageNet Large Scale Visual Recognition Challenge。

建效率,一些研究人员便通过各自所采用的计算机语言将此类重复性的基础代码封装成不同框架。深度学习框架可令使用者更快速便捷地构建深度学习模型,且无需深入了解基础算法细节,这对于深度学习跨学科领域的应用推广具有重要意义。以深度卷积神经网络实现计算机视觉涉及大量并行计算,需借助统一的平台实现计算资源的集成化调用。目前

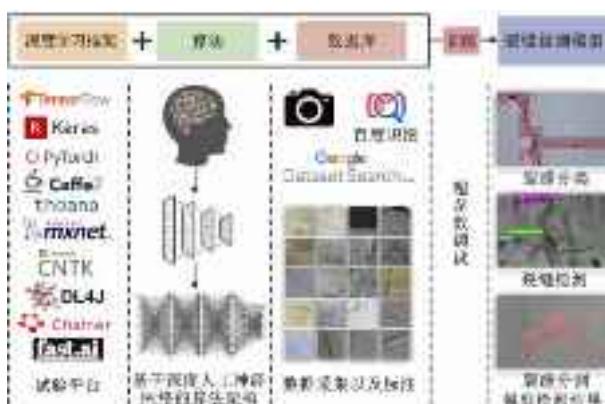


图2 基于深度学习的裂缝检测流程

Fig. 2 Flowchart of DL-based Crack Detection

有许多开源深度学习框架以其优异性能被不同领域广泛使用^[2],包括TensorFlow、Caffe、PyTorch、CNTK、Theano、MXNet、Chainer和Keras等。表2总结了目前流行的深度学习框架。其中,TensorFlow与PyTorch分别被工业界与学术界广泛采用,这2种框架的主要区别在于TensorFlow是一个静态的框架,即加载数据必需在设计好整个深度学习模型的结构后进行,而PyTorch是一个动态的框架,可在对每层模型进行搭建的过程中不断输入数据,然后观察每一层神经网络的输出,并对模型进行实时修改。GitHub作为最大的深度学习源码共享平台之一,广泛被学术界和工业界所使用,其用户反馈也具有较高的参考价值。图3从收藏量、拷贝量、关注量、维护人员4个方面总结了近期GitHub上不同深度学习框架的活跃度情况(图3横坐标为深度学习框架名称,统计截至2021年11月)。从图3可知,由谷歌人工智能团队Google Brain开发和维护的TensorFlow工作流程相对容易,应用程序接口稳定且兼容性好,是目前使用最为广泛的深度学习框架。

表2 典型深度学习框架汇总

Table 2 Summary of Typical Frameworks of Deep Convolution Neural Network

框架	核心编程语言	界面语言支持	CNN/RNN 支持
TensorFlow	Python,C++	Python,C/C++,Java	是/是
Torch/PyTorch	C,Lua	Python,C/C++,Lua	是/是
Keras	Python	Python,Matlab	是/是
Caffe	C++	Python,Matlab	是/是
Theano	Python	Python	是/是
CNTK	C++	Python	是/是
MXNet	Python,C++,R	Python	是/是
Chainer	Python,C/C++	Python	是/是
DL4J	C/C++	Python,Java	是/是
Fast.AI	C,Lua	Python,C/C++,Lua	是/是

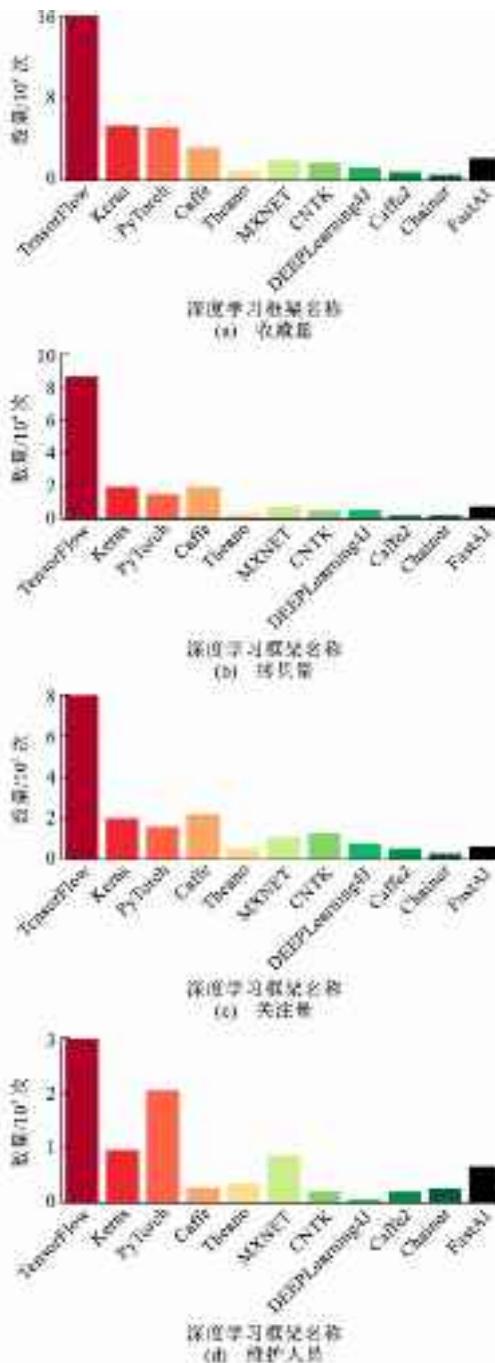


图3 深度学习框架 GitHub 用户活跃情况

Fig. 3 User Activity of DL Frameworks on Github

3 算 法

深度学习作为机器学习的一个分支,近年来由于其在目标检测和语义分割方面的出色表现而备受关注^[31]。受深度学习算法在医学视觉检测领域成功应用的启发,Zhang等^[49]于2016年首次将深度卷积神经网络应用于裂缝检测任务,对智能手机所拍摄图像中的裂缝进行分类,为裂缝的智能化检测提供了一种新的思路。基于深度学习的裂缝检测算

法可分为三大类,即裂缝图像分类(图像级分类和图像补丁级分类)、基于区域的裂缝检测和基于像素的裂缝分割^[7]。图4对3种算法的检测结果进行了可视化展示。



图4 深度学习裂缝检测算法类型可视化结果

Fig. 4 Visualization Results of Different DL Crack Detection Algorithms

3.1 裂缝图像分类算法

裂缝图像分类的目的是确定图像内是否包含裂缝,若存在则将其归为正样本,反之为负样本。裂缝图像的正负样本分类是定位并提取裂缝详细信息的前提,前期分类错误将直接影响后期裂缝危害评估的准确性以及维护方案的制定。为此,一些研究人员针对包含结构裂缝的完整图像进行分类。Gopalakrishnan等^[50]提出将预训练深度卷积神经网络模型用于裂缝图像数据的迁移学习,结合无人机技术对民用基础设施图像中的裂缝损伤进行检测。Silva等^[51]开发了一种基于VGG16架构的图像分类算法,对混凝土表面裂缝进行识别,该模型很大程度上消除了混凝土表面明暗程度、粗糙度和湿度对检测结果的影响。Xu等^[52]提出了一种基于卷积空间金字塔池化模块和深度可分离卷积神经网络架构的裂缝检测方法,在没有预训练的情况下其精度就超过了常规卷积神经网络模型。

与此同时,部分研究人员将包含裂缝的原始图像切割成多张小尺寸图像,进行图像补丁级分类^[53-55]。Schmugge等^[56]利用微调后的CNN检测子图像内是否包含裂缝,实现了核电厂冷却塔表面裂缝的分类。Cha等^[57]将CNN应用于混凝土裂缝检测领域,将分类获得的裂缝子图像在空间上进行重构,实现了结构表面微裂缝的识别与定位。Chen

等^[58]提出了一种称为NB-CNN的深度学习网络架构,用于分析视频中的单帧图像裂缝,实现了相邻关键帧中提取信息的聚合,增强了检测系统的准确性和鲁棒性。Xu等^[10]设计了一种改进的卷积神经网络,并对桥梁钢箱梁内含有复杂干扰信息的裂缝图像进行了分类。如图5所示,该改进方法通过在常规卷积神经网络各阶段尾端添加能够读取特征图关键信息的旁路结构,较大幅度地提升了模型的检测精度。研究人员基于AlexNet对实际场景下的混凝土结构表面图像进行特征提取,实现了裂缝子图像的精确分类^[59-61]。此外,Tang等^[62]搭建了一种基于AlexNet改进结构的检测模型,用于路面裂缝的自动识别,该模型突破了常规CNN主干对输入图像尺寸的限制。随着ResNeXT^[63]、CSPDarknet^[64]和UmNet等^[65]更深层主干网络的提出,裂缝分类模型已达到甚至超越了肉眼对裂缝的分辨能力。最近有研究人员^[66]提出的一种使用深层卷积神经网络自动分类3D裂缝子图像数据的新方法,其分类精度高于94%。

表3对当前裂缝分类算法进行了总结,可以看出裂缝分类研究主要集中于补丁级分类。与图像级分类相比,补丁级分类首先需要将图像切割成子块,该过程可生成更多数据;其次,通过对原始图像的子图像块进行分类与重组,可获得原始图像中裂缝的位置信息^[67],其分类结果可进一步用于裂缝类型分类^[68-69]。尽管补丁级分类可以获得裂缝的位置信息,但其运算步骤相对繁琐且结果粗糙,因而无法用于裂纹特征的精细化评估。

3.2 基于区域的裂缝目标检测算法

目标裂缝的位置信息对其危害等级评估有重要意义。基于区域的目标检测算法可同时实现裂缝的分类以及定位。大量学者基于不同结构的卷积神经网络主干和框架^[39],利用不同的训练方法得到了许多不同的裂缝检测模型。

Cha等^[72]提出了一种基于Faster R-CNN的混凝土结构缺陷检查方法,实现了包括裂缝在内的5种损伤类型的实时检测。廖延娜等^[73-74]提出了一种基于YOLOv3改进的混凝土表观缺陷检测器,用于检测公路桥梁裂缝在内的多种混凝土缺陷,其检测精度较原始YOLOv3提高了1.3%。Jiang等^[71]提出了一种改进的混凝土损伤目标检测与分类方法。该方法采用了一种新的深度可分卷积、逆残差网络结构和线性瓶颈结构对目标检测算法进行优化,大幅提高了混凝土损伤裂缝检测的精度和效率。为实

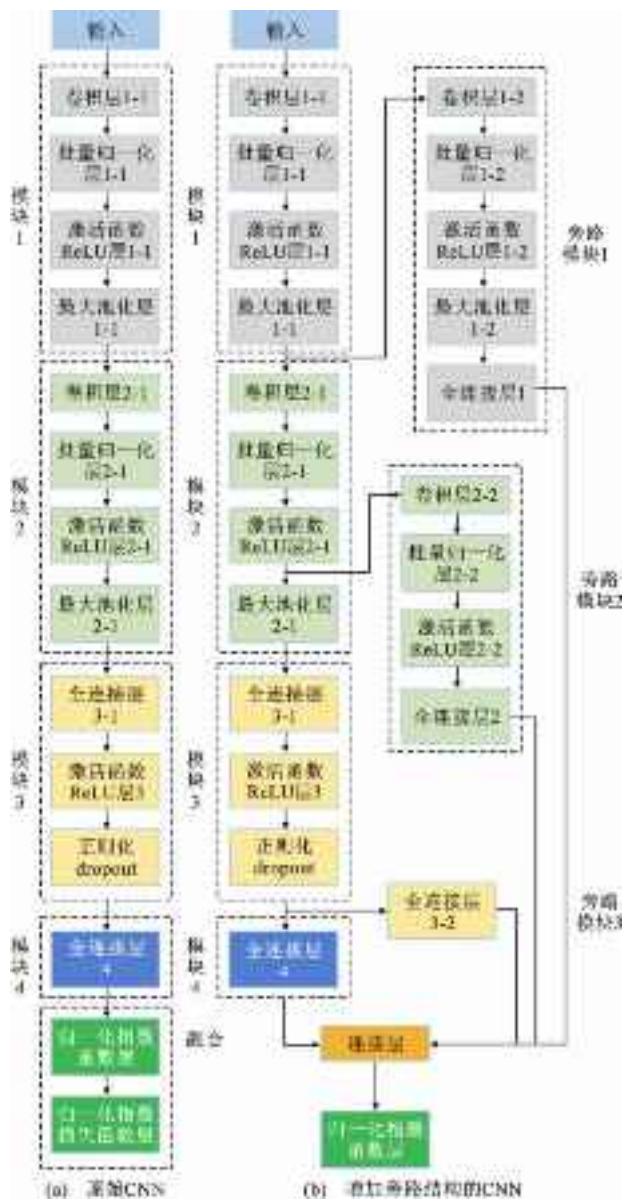
图 5 改进的卷积神经网络^[10]Fig. 5 An Improved Convolutional Neural Network^[10]

表 3 裂缝分类算法相关细节汇总

Table 3 Summary of Relevant Details of Crack Classification

检测精细化程度	相关文献	识别尺寸/(像素×像素)
图像级别	[70]	224×224
图像级别	[50]	3 072×1 425
补丁级别	[71]	416×416
补丁级别	[12], [51], [57], [61], [66]	256×256
补丁级别	[59], [60], [67]	227×227
补丁级别	[52], [56], [68]	224×224
补丁级别	[58]	120×120
补丁级别	[49], [53]	99×99
补丁级别	[54], [55]	64×64

现检测的便捷化, Maeda 等^[75] 将深度 CNN 模型集

成到手机端, 实现了 8 种路面损伤的高精度识别。在此基础上, Mandal 等^[76] 提出了一种基于 YOLOv2 的路面遇险自动分析系统, 以准确快速地对亟需维修的道路裂缝进行检测。该检测器虽然在检测速度上满足要求, 但时常发生漏检和误检。为了进一步提高裂缝检测器的检测精度及鲁棒性, Nie 等^[77] 在基于 Faster R-CNN 的路面裂缝检测架构基础上进行了小规模的迁移学习, 取得了不错的效果。Xue 等^[78] 提出了一种用于隧道衬砌缺陷自动分类的全卷积网络模型, 在减少计算量的同时保障了检测精度。受限于规则卷积核的采样方式, 如图 6 所示, 基于卷积神经网络的常规检测算法难以根据裂缝形状进行精确采样。因此, Deng 等^[79] 通过在检测模型中嵌入可变形运算模块, 提高了检测器对于平面外裂缝的检测精度。表 4 总结了上述基于区域的裂缝目标检测器在各自数据集上的最优表现。从表 4 可以看出就检测精度而言, R-CNN 类检测器在总体趋势上要明显优于 YOLO、SSD 等单级检测算法。这是因为 R-CNN 类目标检测算法分两步解决目标检测问题, 首先通过产生多个目标候选框大致确定目标在图像中的位置, 然后再对候选框做分类及更精确的位置回归。而诸如 YOLO 和 SSD 这类单级检测算法将目标预测和目标定位在同一卷积运算中实现, 提升检测速度的同时也牺牲了一定的检测精度。

裂缝目标检测算法在裂缝分类算法的基础上实现了更为智能化的裂缝定位, 但依旧无法从生成的边界框中自动获取裂缝具体形态、走势等精细化信息, 不利于裂缝危害评估及维护决策的制定。因此, 一些近期的相关研究主要集中于像素级裂缝检测。

3.3 基于像素的裂缝检测算法

为实现更为精细化的裂缝检测, 研究人员基于深度学习语义分割算法开展了像素级裂缝检测。表 5 从精度、计算效率等方面对当前主流语义分割算法进行了总结。基于编码器-解码器结构的模型是应用最为广泛的像素级裂缝检测器, 目前已有大量学者基于 FCN、Segnet 及 U-Net 等网络架构对结构裂缝开展了像素级别的检测^[80-83]。Yang 等^[84] 基于 FCN 架构实现了裂缝的分割, 利用裂缝中心单位像素获取了裂缝定量信息。Li 等^[85] 在 ResNet-50 和全卷积网络(Fully Convolutional Networks, FCN)的基础上, 提出了一种基于深度学习的细裂纹分割网络 FCS-Net。采用空洞空间金字塔池化(Atrous Spatial Pyramid Pooling, ASPP)和批处理归一化

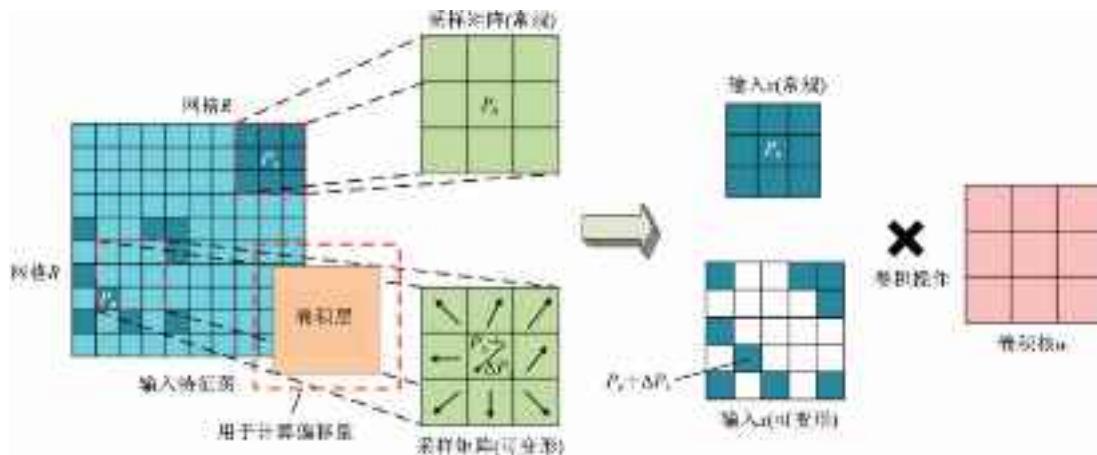
图 6 可变形卷积模块原理^[79]Fig. 6 Schematic of Deformable Convolution Module^[79]

表 4 基于区域的裂缝目标检测器总结

Table 4 Summary of Region-based Crack Detection

文献编号	年份	算法架构	特征提取网络	裂缝检测精度/%
[72]	2018	Faster R-CNN	ZF-Net(经过微调)	90.90
[73]	2018	YOLOv3	DarkNet-53	76.50
[75]	2018	SSD	Inception V2、MobileNet	77.71
[76]	2018	YOLOv2	个人搭建的卷积神经网络	88.51
[77]	2018	Faster R-CNN	ResNet50	96.67
[78]	2018	R-FCN	GoogLeNet(经过微调)	95.84
[79]	2020	FPN Faster R-CNN	ResNet-101	91.58
		R-FCN		90.01
		Faster R-CNN		92.11

(BatchNorm, BN)模块与原有的 ResNet-50 进行协作, 提高并优化了模型对钢结构裂缝的分割能力。 Liu 等^[86] 将扩展的 FCN 和深度监督网络组合, 提出了一种名为 DeepCrack 的深度分层 CNN 架构, 以端到端的方式对裂缝图像进行更为精准的像素级分割。深度学习作为像素级裂缝检测的最新方法, 依赖大量源-目标图像^[87], 而工程实际中往往难以采集到足够数量的训练样本。为解决此问题, 部分研究人员从算法层次上对网络结构进行了改进。 Wang 等^[88] 提出了一种结合全卷积神经网络和多尺度结构的图像分割算法, 有效地识别了钢梁图像中的微小裂纹。 Jenkins 等^[89] 提出了一种经过改进的深层 FCN, 利用很小的数据集获得了较为精确的表面裂缝像素级检测结果。随后, Tabernik 等^[90] 提出了一种基于分割的两阶段深度学习架构, 仅需 25~30 个训练样本即可获得性能优异的裂缝分割模型。 Zhang 等^[91] 提出了一种基于生成对抗网络(Generative Adversarial Networks, GAN)的自监督网络

表 5 语义分割算法及其性能总结

Table 5 Summary of Semantic Segmentation Algorithm

理论	特征提取结构	精度	计算效率	代码开源
Fully Convolutional Network	VGG16(FCN)	★	★	是
SegNet	VGG16+Decoder	★★★	★★	是
Bayesian SegNet	SegNet	★★★	★	是
DeepLab	VGG-16/ResNet-101	★★★	★	是
MINC-CNN	GoogleLeNet(FCN)	★	★	是
CRFasRNN	FCN-8s	★	★★	是
Dilation	VGG-16	★★★	★	是
Enet	Enet bottleneck	★★	★★★	是
Multi-CNN-Raj	VGG-16(FCN)	★★★	★	否
Multi-CNN-Eigen	Custom	★★★	★	是
Multi-CNN-Roy	Multi-scale-CNN-Eigen	★★★	★	否
Multi-CNN-Bian	FCN	★★	★	否
ParseNet	VGG-16	★★★	★	是
ReSeg	VGG-16+ReNet	★★	★	是
LSTM-CF	Fast R-CNN+DeepMask	★★★	★	是
2D-LSTM	MDRNN	★★	★★	否
rCNN	MDRNN	★★★	★★	是
DAG-RNN	Elman network	★★★	★	是
SDS	R-CNN+Box CNN	★★★	★	是
DeepMask	VGG-A	★★★	★	是
SharpMask	DeepMask	★★★	★	是
MultiPathNet	Fast R-CNN+DeepMask	★★★	★	是
Huang-3DCNN	Own 3DCNN	★	★	否
PointNet	Own MLP-based	★★	★	是
Clockwork Convnet	FCN	★★	★★	是
3DCNN-Zhang	Own 3DCNN	★★	★	是
End2End Vox2Vox	C3D	★★	★	否

架构, 该网络可在无真实标记数据的情况下进行有效训练。

部分研究人员在现有语义分割网络架构的基础上,通过嵌入不同功能模块以提升网络对裂缝的检测性能^[92]。Yang 等^[93]提出了一种特征金字塔分层增强网络用于道路裂缝检测,其准确性和可推广性超越了最新的边缘检测和语义分割方法。Fan 等^[94]提出了一种具有分层特征学习能力和扩张卷积的编码器-解码器体系结构,该方法通过提取和融合不同大小和不同级别的裂缝特征图实现识别精度和检测敏感性的提升。随后,Fan 等^[95]提出了一种基于概率融合的卷积神经网络,用于道路裂缝的检测,其性能在 2 个公共裂缝数据集(CFD 和

AigleRN)上得到了证实。为进一步提升检测器在实际场景下的检测能力,König 等^[96]提出了一种用于混凝土裂缝语义分割的深度编码器-解码器架构,通过添加深层监管和上采样组件,提高了其在 4 个公开裂缝分割数据集上的检测精度。研究表明裂缝周围的高级别语义信息可以更好地辅助目标裂缝逐像素检测。因此,Liu 等^[97]提出了一种用于路面裂缝检测的深度学习网络。通过引入多重膨胀模块以及上采样模块,实现了更为高效准确的裂缝像素级检测,在 CFD 数据集和 G45 数据集上都展现出很高的识别精度。图 7 展示了上采样模块的运算流程。

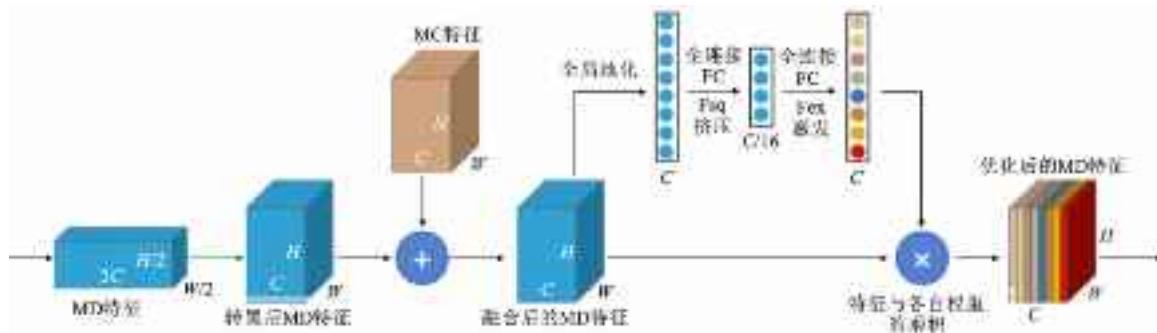


图 7 SE-上采样模块^[97]

Fig. 7 SE-upsampling Module^[97]

由于视觉传感设备的进步,3D 图像数据也逐渐被应用于结构健康监测。部分学者开发了对 3D 裂缝图像进行分割的 CNN 架构^[98-100],此类架构相较于 2D 图像检测架构可获得更多裂缝表观细节信息并大幅降低误检率。Zhang 等^[101]提出的一种名为 CrackNet-R 的递归神经网络(Recurrent Neural Network, RNN)架构实现了沥青路面 3D 裂缝图像的全自动像素级检测,是为数不多应用 RNN 进行裂缝检测的案例。此外,部分学者将基于深度学习的语义分割框架嵌入无人机系统^[102-104],实现了常规设备难以抵达结构部位裂缝的高效检测。

图 8 统计了近 6 年来基于深度学习的裂缝检测的部分期刊论文中各类算法的占比(数据源摘自 Web of Science)。从图 8 可以看出,基于补丁级分类和语义分割算法的论文占比最大。由于补丁级分类仅需利用轻量级 CNN 模型即可实现裂缝图像的分类及初步定位,它在基于深度学习的语义分割算法诞生之前已被广泛应用。语义分割算法能更准确地提供精细化裂缝定量信息,将成为未来研究的重点。

此外,近期被提出的 Transformer 是一种有别于 CNN 而完全基于自注意力机制的深度神经网

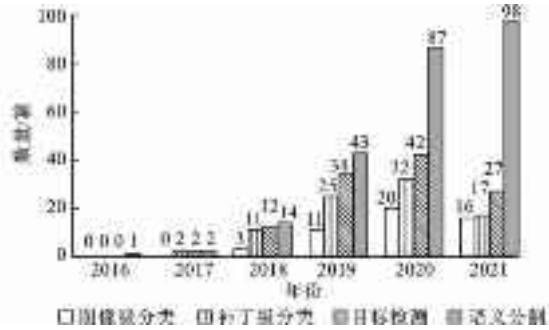


图 8 近 6 年基于深度学习的裂缝检测论文发表情况

Fig. 8 Publication of Crack Detection Papers

络,受其在自然语言处理领域所表现出强大能力的启发,研究人员将 Transformer 网络扩展到计算机视觉任务^[105]。Vision Transformer 逐渐成为计算机视觉领域的热门话题,其在图像分类、目标检测以及语义分割任务中都展现出了 CNN 所不具备的潜能^[106]。Chen 等^[107]通过训练一个基于回归序列的 Transformer 自动像素预测模型,使其结果在图像分类任务上超越了传统 CNN。ViT 是 Dosovitskiy 等^[108]最近提出的 Vision Transformer 模型,其在多个图像识别数据库上都表现出最优的性能。除了基本的图像分类,Transformer 还被用于解决目标检

测^[109-111]和语义分割^[112-114]的问题。已有学者^[115-116]提出了基于Transformer的裂缝分割模型,获得了更为精细化的像素级裂缝检测结果。在后续的研究中,Transformer有望取代CNN深度学习模型并进一步推进裂缝高精度智能化检测的发展。

4 数据集

深度学习的成功不仅取决于优良的算法,与大数据支持和高性能计算设备的发展也密不可分。数据集作为引导深度学习模型进行信息理解的信号源,很大程度上决定了训练模型的最终性能。表6统计了可用于裂缝分类、目标检测以及像素级分割的部分公开裂缝数据集。手动标注像素级标签是一项非常耗时且费力的工作,因此,用于裂缝分割的数据集的样本数量远小于裂缝分类和裂缝目标检测数据集,目前也尚无大规模的用于裂缝分割的公开数据集。

除上述公开数据集外,部分学者在实验室环境下创建了个人裂缝数据集,用于特定环境下裂缝的识别与检测^[117-119]。权衡训练成本及检测器性能,此类数据集中裂缝图像尺寸大都控制在200像素×200像素~300像素×300像素之间。也有少量学者运用更小尺寸的图像补丁块进行模型训练^[120-121]。需要注意的是,虽然此类数据集中图像尺寸较小,但图像数量都超过了14 000张。例如,Li等^[122]搜集了尺寸仅为18像素×18像素的32 600张裂缝灰度补丁图像,其训练模型也表现出了不错的检测敏感性与检测精度。为尽可能避免诸如核电站等安全等级要求极高的结构存在裂缝检测的误判,Chen等^[58]搜集了3 000 000张尽可能包含实际情况下所有类型裂缝的图像补丁进行大规模数据模型训练。除上述运用常规可见光相机拍摄图像外,Jang等^[123]建立的数据集中还包含部分红外裂缝影像数据,实现了对宏观及微观裂缝更敏感的检测,这是首次将不同拍摄源的图像混用于深度学习裂缝检测模型训练。为解决现场图像难以获取的困难,部分学者利用从互联网上爬取的裂缝图像进行模型训练^[60,79],其训练模型在实际检测中也获得了不错的效果。随着传感器技术的发展,激光扫描获取的高分辨率3D数据也逐渐被应用于结构裂缝检测^[98]。与平面图像相比,3D激光在数据采集过程中对光照不敏感,可有效排除相关噪声干扰,提高裂缝识别精度^[124]。图9总结了部分研究者建立的裂缝数据集。

5 评价指标

表7总结了基于深度学习的裂缝检测模型性能评价常用指标。精确度、召回率和F₁分数是常用的3个评价指标^[49]。分类算法中真阳性(True Positive, TP)、假阳性(False Positive, FP)、真阴性(True Negative, TN)和假阴性(False Negative, FN)是计算评价指标的重要参数。正负样本不平衡条件下需设置适当阈值来获取较为合理的检测结果。裂缝正负样本阈值设定因检测对象而异,低风险项目的阈值可适当提高。对于关键工程结构而言,漏检可能会导致灾难性后果,因此对于召回率具有较高要求^[60]。F₁分数是精度和召回率的调和平均值,可更加全面地评估裂缝检测模型的性能。值得注意的是,为了获得较为客观的F₁分数,往往需要重新估计用于确定最终概率的阈值^[130]。对于指标Accuracy而言,其值往往会因样本数量不均匀而产生偏差性结果,一般只在样本数量均匀时才被使用。PR(Precision-recall)曲线也被作为评价指标,但其曲线端部无法真实反映低精确率和高漏检率等极端情况。ROC(Receiver Operating Characteristic)曲线受不平衡样本影响小,其曲线与坐标轴所包围面积(Area Under Curve, AUC)常被作为衡量分类模型的综合性指标。

裂缝目标检测任务中的TP和FP由预测区域与真实区域的交并比(Intersection over Union, IoU)决定^[76],其计算方式如图10所示。IoU越接近1,则表示检测结果越精确。值得注意的是,检测模型会对每个锚框进行分类,因此仅当预测锚框与真实目标框属于相同类别时,IoU的计算才有效。考虑到目标先验分布的不均匀性,目标检测任务的评价指标会在分类任务的基础上增加AP(Average Precision)、mAP(mean Average Precision)和缺失率曲线。AP主要有2种计算方法,大部分研究将Salton和McGill^[131]提出的11点内插AP应用于模型评估。另一种是目前最常用的计算方法,即Natural Integra方法^[34],该方法通过计算PR曲线包围面积获得AP。

裂缝分割算法有别于分类及目标检测算法,在宏观上属于定量分析方法。分割算法中的TP、FP、FN和TN都是针对各类别裂缝像素而言,考虑到人工标注的主观差异性,判别误差一般允许在真实像素区域边缘正负2~5个像素点以内^[89]。为进一步减小主观随机性的影响,Tsai和Chatterjee^[132]提

表 6 已公开的裂缝检测数据集
Table 6 Open Source Crack Detection Datasets

数据集	数据集描述	目的
CFD(Crack Forest Dataset) ^[125]	包含 118 张大小为 480 像素×320 像素的道路裂缝图像。每个图像都有手动像素级标记的裂纹轮廓	语义分割
Aigle-RN ESAR Tempest2, LCMS, and LRIS ^[126]	包含 269 张 256 像素×256 像素的路面裂缝图像。其中 30 张图像对于裂缝进行了像素级标注	语义分割
CRACK500 ^[93]	在天普大学主校区采集了 500 张大小约为 2 000 像素×1 500 像素的道路裂缝图像，并都进行了像素级标注。是目前最大的像素注释的路面裂缝数据集	语义分割
Deep Crack-DB ^[86]	包含 537 张大小为 544 像素×384 像素的不同场景裂缝图像。每个图像都有手动像素级标记的裂纹轮廓	语义分割
CrackTree dataset ^[127]	包含 206 张大小为 800 像素×600 像素的不同场景裂缝图像，被用于分割模型的性能评估。每个图像都有手动像素级标记的裂纹轮廓	语义分割
CRKWH100 ^[80]	包含 100 张大小为 512 像素×512 像素的路面裂缝图像，line-array camera 拍摄，被用于分割模型的性能评估。每个图像都有手动像素级标记的裂纹轮廓	语义分割
Stone331 ^[80]	包含 331 张大小为 512 像素×512 像素的石材裂缝图像，area-array camera 拍摄，被用于分割模型的性能评估。每个图像都有手动像素级标记的裂纹轮廓	语义分割
IPC-SHM2020 ^[83]	原始数据集获得第一届国际结构健康监测项目竞赛(IPC-SHM 2020)组委会授权。包含用于训练和测试的 120 对图像标签对，以及额外的 80 幅没有标签部分的原始钢结构疲劳裂纹图像，图像的分辨率分别为 4 928 像素×3 264 像素和 5 152 像素×3 864 像素	语义分割
Cracks dataset of steel beams ^[88]	第 1 个钢梁裂缝数据库包含 1 800 张大小为 1 280 像素×960 像素的裂缝图像，按照 1:1:1 的比例被划分为用于模型训练、验证和测试的子集。第 2 个钢梁裂缝数据集共包含 2 156 张大小为 550 像素×410 裂纹图像，用于训练、验证和测试的图像数量分别为 800、580、776 张	语义分割
GAPs384 ^[93]	从 GAP 数据集中选取了 384 张大小为 1 920 像素×1 920 像素的沥青路面缺陷图像，并进行逐像素注释	语义分割
GAP(German Asphalt Pavement Distress) ^[55]	包含 1 969 张大小为 1 920 像素×1 920 像素的沥青路面缺陷图像(裂缝、坑洼、镶嵌斑块等)	目标检测
CQU-BPDD ^[62]	包含 60 059 张 1 200 像素×900 像素的沥青路面病害图像(横向裂纹、块状裂纹、鳄鱼形裂纹、浇注裂纹、纵向裂纹、撕裂、修复和正常裂纹)	分类
Laser-scanned Range Crack Image ^[128]	包含 5 000 个裂纹和 5 000 个非裂纹的激光扫描图像补丁，用于沥青和混凝土巷道裂缝分类器的训练	分类
Concrete Crack Images for Classification ^[49]	包含 40 000 张 227 像素×227 像素的混凝土建筑表面图像，其中部分带有裂缝，部分无裂缝	分类以及语义分割
SDNET2018 ^[129]	包含 56 000 张 256 像素×256 像素的开裂和未开裂的混凝土桥面板、墙壁和人行道的图像	分类

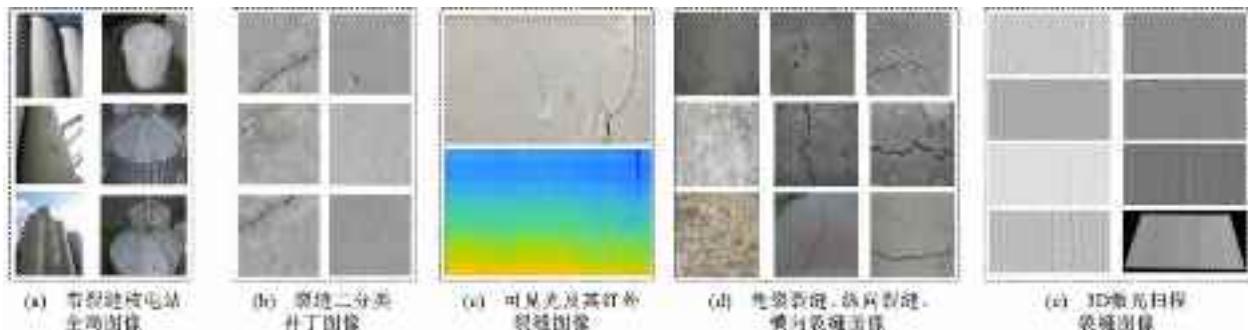


图 9 个人裂缝数据集内部部分图像
Fig. 9 Part of Image in Personal Crack Datasets

表 7 深度学习模型性能评价指标

Table 7 Performance Evaluation Index of DL Model

指标	指标值及计算公式	相关曲线
true positive	T_P	
false positive	F_P	
true negative	T_N	
false negative	F_N	
Precision	$P_{RC} = \frac{T_P}{T_P + F_P}$	PR
Recall	$Rec = \frac{T_P}{T_P + F_N}$	PR, ROC
F1-score	$F_1 = \frac{2P_{RC}R_{EC}}{P_{RC} + R_{EC}}$	PR
Accuracy	$A_{cc} = \frac{T_P + T_N}{T_P + F_N + F_P + T_N}$	ROC
Area under Precision-recall	$A_{P_1} = \int_0^1 p(r) dr$ $A_{P_2} = \frac{1}{11} \sum_{r \in \{0, 0.1, 0.2, \dots, 1\}} \max_{\tilde{r}; \tilde{r} \geq r} p(\tilde{r})$	PR
mean Average Precision	$V_{mAP} = \frac{\sum_{i=1}^K A_{P_i}}{K}$	



图 10 交并比示意

Fig. 10 Illustration of Intersection Over Union

出了增强型 Hausdorff 距离度量。Li 等^[133]指出现有的评价指标存在严重低估裂缝检测精度的可能,因此,提出了一种名为 CovEval 的裂缝分形评估标准,以纠正评价结果误差。

6 针对不同基础设施的裂缝检测应用

基于深度学习算法准确检测裂缝并评估结构安全的前提是有效采集待检测区域的图像数据。传统图像采集依赖专业人员手持采集设备进行近距离拍摄,不利于对人员难以抵达的数据采集盲区的结构裂缝进行检测和评估。打造日趋智能化、灵活机动的裂缝图像采集设备以解决人工裂缝图像采集低效、作业危险等问题符合行业当下及未来的发展需求。近年来部分研究人员针对不同类型的土木基础

设施开发了相应的基于机器视觉的裂缝检测机器人平台并尝试将其应用于实际工程(图 11)。

6.1 道路

道路裂缝是土木基础设施中最主要与最常见的裂缝,而道路裂缝检测是公路交通管理部门的重要工作之一。传统采用人工或基于道路检测车的裂缝检测方法在评估服役道路状况时存在数据处理效率低、成本高的缺点。为了克服这些问题,2005 年 Cho 等^[134]设计了一款半自动路面裂缝跟踪机器人。该设备能准确检测裂缝位置,但其移动速度慢,需在无车流或者少车流的路面进行裂缝检测工作,检测效率较低,不宜用于交通量较大的路面裂缝检测。随着深度学习和智能机器人的发展,各类基于深度神经网络架构的裂缝检测算法被部署在机器人上,用于路面状况快速检测^[135],并配有道路清扫^[136]或修补功能^[137],实现了对路面裂缝自动化较高、鲁棒性较好的检测和养护。然而,以上与路面接触的裂缝检测机器人只适用于小范围的路面裂缝检测。为了避免堵塞交通,扩大监测范围,Pan 等^[138]设计了一款非接触式的无人机,实现了对大范围路面裂缝的空中巡测。

6.2 桥梁

桥梁多跨越水域及峡谷,其结构时常暴露在潮湿空气、强风以及大温差等恶劣环境中,结构各部分(包括桥面板、桥面梁、桥墩以及桥台等)均易出现裂缝、腐蚀、剥落等不同类别的结构损伤。桥梁裂缝检测是桥梁养护的重要内容之一。La 等^[139]将一种先进的无损检测技术集成到自动机器人上,并于 2013 年在美国华盛顿特区的阿灵顿纪念大桥上部署了基于该机器人的桥面无损检测系统,实现了高噪声下桥面混凝土结构裂缝的准确检测,并构建了桥面的整体裂缝分布图。然而,此类机器人无法检测桥梁底部的裂缝。Leibbrandt 等^[140]设计了一种具有攀爬功能的机器人,可吸附在桥梁底部对裂缝进行检测。对于桥梁的垂直结构(包括桥墩、桥台等),可采用爬壁机器人实现裂缝检测(有腿的机器人^[141-142]、基于轮子的机器人^[143])。此外,Jang 等^[144]设计了一种环形攀爬机器人可实现对整个高桥墩裂缝的检测,避免高空作业带来的安全隐患。Xie 等^[145]开发了一种智能检测车辆,可通过伸缩机械臂对桥梁水面以上结构部位(桥面板、桥面梁、桥台和桥墩)进行裂缝检测。但对于大量中小型桥梁和城市地下涵洞,采用常规方法和装置难以有效检测结构底部。He 等^[146]提出了一种结合目标检测算法和无人水面舰



图 11 裂缝检测机器人应用案例

Fig. 11 Application of Robots on Crack Detection

艇的方案有效解决了操作空间受限的结构裂缝检测问题。对于淹没在水下的桥梁基础设施,需采用水下机器人^[147]对裂缝进行检测。近年来,随着无人机的快速发展与推广,研究者利用无人机实现了对桥梁上部结构裂缝快速高精度的检测^[148-149]。最近一些研究人员研发了集成多种运动模式的裂缝检测机器人,诸如具有行走功能的无人机或具有爬行功能的无人机^[150-151]。

6.3 隧道

隧道裂缝检测的环境不同于路面和桥梁,隧道作业环境恶劣,粉尘多、湿度大且缺乏自然光。隧道的光照条件对裂缝检测具有较大的影响。隧道裂缝检测又分为公路隧道裂缝检测和轨道隧道裂缝检测。针对公路隧道检测,2006年,Yu等^[152]提出了一种适用于隧道环境的半自动裂缝检测移动机器人集成系统。该机器人配备了高功率照明装置以解决隧道照明较暗的问题,实现了对隧道表面裂纹较为准确、快速的检测。随后,Protopapadakis等^[153]将一种基于深度学习的混凝土隧道表面裂缝检测算法嵌入到 ROBO-SPECT 机器人平台,并在希腊 Metsovo 的 Egnatia 高速公路隧道中进行了试验验证。研究结果表明,该方法在隧道较暗的照明条件下也能有效地识别裂缝,从而实现了隧道裂缝全自动检测。

轨道隧道相比公路隧道其环境更为复杂,人工

采集轨道隧道图像的时间受限,效率低且成本高。针对上述情况,Leonidas 等^[154]开发了一种能沿轨道移动的机器人,可在铁路隧道环境下自动检测隧道混凝土表面的裂缝。王平让等^[155]开发了基于电荷耦合器件(Charge Coupled Device, CCD)摄像机和灯的地铁隧道检测机器人,可在光线较暗的地铁隧道环境中采集高清图像。在此基础上,日本 Keisokukensa 推出了 MIMM-R 隧道检查系统,能以 $70 \text{ km} \cdot \text{h}^{-1}$ 的速度和 0.2 mm 的分辨率检测裂缝。黄宏伟等^[156]设计了一种基于多台 CCD 摄像机阵列的隧道裂缝检测移动设备,目前该设备已成功应用于上海、长沙地铁隧道的裂缝检测。

6.4 房屋建筑

建筑结构表面裂缝检测主要分为室内检测和室外检测。室内检测主要是针对施工完成后的建筑物进行质量评估。Yan 等^[157-158]开发了一种全自动施工质量评估机器人系统,用于解决空心、裂缝、均匀度、对准和倾斜等问题。建筑室外检测相比室内检测较为不便,尤其对于高层建筑,高空作业甚为危险。为此,Choi 等^[159]开发了基于小型飞行器的结构检测图像采集系统,远程控制小型飞行器接近高层结构,以识别建筑物的裂缝。De 等^[160]使用配备传感装置的攀爬机器人对建筑物的墙壁或屋顶等表面的裂缝进行检测。针对高层玻璃幕墙,Kouzehgar 等^[161]开发了清扫机器人 facade-cleaning,该机

器人带有裂缝检测功能。此外, Torok 等^[162]采用无人机收集震后受损建筑物图片, 并基于三维图像重建技术和裂缝检测算法实现对建筑构件表面缺陷与损伤的检测和分析。该方法成功应用于海地太子港震后受损办公大楼的结构安全评估。

以上综述了不同裂缝检测机器人在 4 类常见土木基础设施场景下的应用案例。针对土木基础设施不同场景的差异性, 研发并应用适用于特定场景的裂缝检测机器人, 可大幅提高裂缝检测效率和精度。道路裂缝检测车和无人机作为道路裂缝检测常用的图像采集设备, 亦广泛用于桥面板裂缝图像采集。但道路裂缝检测车需要配置灯光设备, 以对光照较暗的公路隧道裂缝进行检测。而对于道路检测车难以抵达的地方, 比如高墩大跨桥梁、桥梁底部、桥墩、高层建筑的外立面等均可采用无人机或具有吸附功能的机器人进行裂缝图像采集。无人机因安全距离限制、抖动等原因, 其检测精度相比吸附式设备低一些。但对于水面以下的桥梁结构、桥梁箱梁内部、隧道及建筑室内结构等无人机无法进入或不方便检测的结构部位, 需要设计具有特定运动功能的裂缝检测机器人。而对于轨道隧道裂缝的检测, 设计沿轨道移动的机器人更能有效解决人工采集轨道隧道图像存在的时间窗口受限、效率低且成本高等问题。

7 结语

开裂是维保期土木基础设施发生灾变的重要诱因, 及早发现裂缝并采取合理的维护措施对于避免灾难性事故的发生具有重要意义。基于深度学习的裂缝视觉检测可有效提高行业整体检测效率并节约运维成本, 符合土木工程领域信息化和智能化的发展趋势, 具有广阔的应用前景。算法、数据集和评价指标是构建深度学习模型的关键要素, 因此本文主要从这 3 个方面对当前基于深度学习的土木基础设施裂缝检测研究进行了系统综述, 并结合工程实际, 总结了裂缝检测机器人平台在道路、桥梁、隧道、房屋建筑这 4 个场景下的应用情况。主要结论如下:

(1) 基于 CNN 主干结构的深度学习算法已被广泛用于结构表面裂缝的精准定位和类别区分, FPN 作为一种多尺度融合方法使用最为广泛, 并在一定程度上提高了检测器对于不同尺寸裂缝的检测性能。虽然 ResNeXT、CSPDarknet 和 GhostNet 等深层主干网络以及相关融合算法进一步提升了模型的检测精度, 但受限于数据标注方式以及算法逻辑, 目前基于深度学习的裂缝检测模型只能作为一种定

性分析工具使用, 难以对裂缝宽度、长度进行准确测量, 裂缝的精细化定量信息仍需依靠传统图像处理技术进行辅助提取。

(2) 现阶段基于深度学习的裂缝检测算法大多通过二维可见光图像分析结构表观裂缝信息, 难以获取裂缝深度信息。3D 激光扫描图像以及红外图像为裂缝深度信息的获取提供了新的解决思路。另外, 通过 Kinect 等红外设备提取裂缝所在场景的深度信息, 利用 RGBD 图像对裂缝信息进行补充, 能提高裂缝识别精度。基于此类数据进行模型训练的相关算法开发将成为未来研究工作的重点。

(3) 相较于裂缝分类和目标检测算法而言, 利用语义分割算法识别土木基础设施裂缝需要依赖大量像素级人工标注, 数据制作成本及专业性高。因此, 该类像素级数据集容量非常有限, 导致当前裂缝分割模型的鲁棒性较差, 制约了其在实际环境下的应用。建立更加全面的裂缝分割数据集, 同时开发小样本训练算法是解决上述问题的有效途径。GAN 作为一种半监督和无监督学习领域的新兴方法, 在确保精度的同时可有效降低训练模型对数据标签的依赖, 是未来裂缝分割研究领域的重要发展方向。另外, 由于裂缝分割任务的像素级数据标注较目标检测与分类任务的图像级标注更为繁琐, 因而无法保障标注人员对每条微小裂缝的边缘区域都进行了精细化的标注, 这间接导致了无法客观评价裂缝检测模型的性能。为此, 提出能消除标注误差影响的边缘评价指标值得深入研究。

(4) 合理的模型性能评价指标对评估裂缝检测模型的性能具有重要作用。Precision 和 Recall 是分类算法中最基础的 2 个评价指标, 但不平衡样本数量会极大影响其评价客观性, 需通过 OARP^[163] (Optimized Accuracy with Recall-precision) 和 AUC 等综合性指标对模型性能进行有效评价。对于裂缝目标检测和分割算法而言, 多数研究人员采用个人建立的裂缝数据集进行训练并采用不同的指标进行模型性能评价, 这不利于准确评估不同裂缝检测模型实际性能的优劣。因此, 有必要建立统一的模型性能测试基准数据集和相应的评价指标体系。

(5) 常规 CNN 主干网络缺乏对目标周围像素的建模能力, 致使主流裂缝检测算法会忽略部分有利于裂缝识别的上下文信息。将视觉注意力模块嵌入 CNN 或者采用完全基于自注意力机制的 Transformer 可帮助模型更好地融合目标周围上下文信

息,并显著提高其在真实场景下的裂缝识别性能。但此类裂缝检测模型的运行在很大程度上依赖高性能GPU,如何在确保精度的同时大幅减少模型参数以及计算成本值得未来重点研究。基于深度学习的裂缝检测模型可辅助管养部门快速准确地制定裂缝管养方案,从而降低运营风险及运维成本。

(6)裂缝检测机器人平台的应用是智能运维的重要基础。目前针对不同的土木基础设施已开发了相应的裂缝检测机器人平台。开发适用场景多,成本低的裂缝检测机器人平台是未来的发展方向。

(7)基于深度学习的裂缝检测一般只能根据裂缝的分布形态进行外观分类,难以判断其是否属于结构性裂缝。结构性裂缝的判断对结构安全评估具有重要意义,如何通过深度学习方法对结构性裂缝进行有效判定值得进一步探讨。

参考文献:

References:

- [1] 《中国公路学报》编辑部.中国桥梁工程学术研究综述·2021[J].中国公路学报,2021,34(2):1-97.
Editorial Department of *China Journal of Highway and Transport*. Review of the academic research on bridge engineering in China: 2021 [J]. *China Journal of Highway and Transport*, 2021, 34 (2): 1-97.
- [2] AZIMI M, DADRAS A, PEKCAN G. Data-driven structural health monitoring and damage detection through deep learning: State-of-the-art review [J]. *Sensors*, 2020, 20 (10): 2278-2312.
- [3] 孙利民,尚志强,夏 烨.大数据背景下的桥梁结构健康监测研究现状与展望[J].中国公路学报,2019,32(11):1-20.
SUN Li-min, SHANG Zhi-qiang, XIA Ye. Development and prospect of bridge structural health monitoring in the context of big data [J]. *China Journal of Highway and Transport*, 2019, 32 (11): 1-20.
- [4] 彭 博,蒋阳升,蒲 云.基于数字图像处理的路面裂缝自动分类算法[J].中国公路学报,2014,27(9):10-18,24.
PENG Bo, JIANG Yang-sheng, PU Yun. Automated classification algorithm of pavement crack based on digital image processing [J]. *China Journal of Highway and Transport*, 2014, 27 (9): 10-18, 24.
- [5] 韩晓健,赵志成.基于计算机视觉技术的结构表面裂缝检测方法研究[J].建筑结构学报,2018,39(增1):418-427.
HAN Xiao-jian, ZHAO Zhi-cheng. Structural surface crack detection method based on computer vision technology [J]. *Journal of Building Structures*, 2018, 39 (S1): 418-427.
- [6] 刘宇飞,樊健生,聂建国,等.结构表面裂缝数字图像法识别研究综述与前景展望[J].土木工程学报,2021,54(6):79-98.
LIU Yu-fei, FAN Jian-sheng, NIE Jian-guo, et al. Review and prospect of digital-image-based crack detection of struc-
- ture surface [J]. *China Civil Engineering Journal*, 2021, 54 (6): 79-98.
- [7] HSIEH Y A, TSAI Y J. Machine learning for crack detection: Review and model performance comparison [J]. *Journal of Computing in Civil Engineering*, 2020, 34 (5): 04020038.
- [8] 毛江鸿,崔 磊,金伟良,等.基于分布式光纤传感的混凝土裂缝识别与监测试验研究[J].传感技术学报,2014,27(9):1298-1304.
MAO Jiang-hong, CUI Lei, JIN Wei-liang, et al. Experimental research on concrete crack recognizing and monitoring based on distributed fiber sensor [J]. *Chinese Journal of Sensors and Actuators*, 2014, 27 (9): 1298-1304.
- [9] 叶宇霄,赵新铭,吴 刚,等.分布式光纤在混凝土结构裂缝监测中的应用[J].土木建筑与环境工程,2018,40(1):24-29.
YE Yu-xiao, ZHAO Xin-ming, WU Gang, et al. Application of distributed optical fiber in the monitoring of cracks in concrete structures [J]. *Journal of Civil, Architectural & Environmental Engineering*, 2018, 40 (1): 24-29.
- [10] XU Y, BAO Y, CHEN J, et al. Surface fatigue crack identification in steel box girder of bridges by a deep fusion convolutional neural network based on consumer-grade camera images [J]. *Structural Health Monitoring*, 2019, 18 (3): 653-674.
- [11] WANG W, DENG L, SHAO X. Fatigue design of steel bridges considering the effect of dynamic vehicle loading and overloaded trucks [J]. *Journal of Bridge Engineering*, 2016, 21 (9): 04016048.
- [12] DORAFSHAN S, THOMAS R J, MAGUIRE M. Comparison of deep convolutional neural networks and edge detectors for image-based crack detection in concrete [J]. *Construction and Building Materials*, 2018, 186 (1): 1031-1045.
- [13] 舒江鹏,李 俊,马亥波,等.基于特征金字塔网络的超大尺寸图像裂缝识别检测方法[J].土木与环境工程学报,2021,43(6):1-9.
SHU Jiang-peng, LI Jun, MA Hai-bo, et al. Crack detection method based on feature pyramid network for super large-scale images [J]. *Journal of Civil and Environmental Engineering*, 2021, 43 (6): 1-9.
- [14] MUNAWAR H S, HAMMAD A W A, HADDAD A, et al. Image-based crack detection methods: A review [J]. *Infrastructure*, 2021, 6 (8): 115.
- [15] ALZUBAIDI L, ZHANG J, HUMAIDI A J, et al. Review of deep learning: Concepts, CNN architectures, challenges, applications, future directions [J]. *Journal of Big Data*, 2021, 8 (1): 1-74.
- [16] SUZUKI K. Overview of deep learning in medical imaging [J]. *Radiological Physics and Technology*, 2017, 10 (3): 257-273.
- [17] HAMISHEBAHAR Y, GUAN H, SO S, et al. A comprehensive review of deep learning-based crack detection approaches [J]. *Applied Sciences*, 2022, 12 (3): 1374.
- [18] LIU Y, YEOH J K, CHUA D K. Deep learning-based en-

- hancement of motion blurred UAV concrete crack images [J]. Journal of Computing in Civil Engineering, 2020, 34 (5): 04020028.
- [19] ELLENBERG A, KONTSOS A, MOON F, et al. Bridge related damage quantification using unmanned aerial vehicle imagery [J]. Structural Control and Health Monitoring, 2016, 23 (9): 1168-1179.
- [20] FLAH M, NUNEZ I, CHAABENE W B, et al. Machine learning algorithms in civil structural health monitoring: A systematic review [J]. Archives of Computational Methods in Engineering, 2021, 28 (4): 2621-2643.
- [21] MCCULLOCH W S, PITTS W. A logical calculus of the ideas immanent in nervous activity [J]. The Bulletin of Mathematical Biophysics, 1943, 5 (4): 115-133.
- [22] DING S, LI H, SU C, et al. Evolutionary artificial neural networks: A review [J]. Artificial Intelligence Review, 2013, 39 (3): 251-260.
- [23] RUMELHART D E, HINTON G E, WILLIAMS R J. Learning representations by back-propagating errors [J]. Nature, 1986, 323 (6088): 533-536.
- [24] HINTON G E, SALAKHUTDINOV R. Reducing the dimensionality of data with neural networks [J]. Science, 2006, 313 (13): 504-507.
- [25] HINTON G, DENG L, YU D, et al. Deep neural networks for acoustic modeling in speech recognition: The shared views of four research groups [J]. IEEE Signal Processing Magazine, 2012, 29 (6): 82-97.
- [26] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. ImageNet classification with deep convolutional neural networks [J]. International Conference on Neural Information Processing Systems, 2017, 60 (6): 84-90.
- [27] DENG L, SELTZER M, YU D, et al. Binary coding of speech spectrograms using a deep auto-encoder [J]. Inter-speech, 2010, 13 (8): 1692-1695.
- [28] DAHL G, RANZATO M A, MOHAMED A R, et al. Phone recognition with the mean-covariance restricted Boltzmann machine [C] // Curran Associates. Proceedings of the 23rd International Conference on Neural Information Processing Systems. New York: NIPS, 2010: 469-477.
- [29] HINTON G E, SRIVASTAVA N, KRIZHEVSKY A, et al. Improving neural networks by preventing co-adaptation of feature detectors [EB/OL]. (2012-07-03) [2021-11-16]. <https://arxiv.org/pdf/1207.0580.pdf>.
- [30] IOFFE S, SZEGEDY C. Batch normalization: Accelerating deep network training by reducing internal covariate shift [C] // BACH F, BLEI D, SCHLKOPF B. International Conference on Machine Learning (PMLR). Gandi: Micromote Publishing, 2015: 448-456.
- [31] PAK M, KIM S. A review of deep learning in image recognition [C] // IEEE. 2017 4th International Conference on Computer Applications and Information Processing Technology (CAIPT). New York: IEEE, 2017: 1-3.
- [32] DENG J, DONG W, SOCHER R, et al. ImageNet: A large-scale hierarchical image database [C] // IEEE. 2009 IEEE Conference on Computer Vision and Pattern Recognition. New York: IEEE, 2009: 248-255.
- [33] LIN T Y, MAIRE M, BELONGIE S, et al. Microsoft coco: Common objects in context [C] // ECCV. 2014 European Conference on Computer Vision (ECCV). Zurich: Springer, 2014: 740-755.
- [34] EVERINGHAM M, VAN G L, WILLIAMS C K, et al. The pascal visual object classes (Voc) challenge [J]. International Journal of Computer Vision, 2010, 88 (2): 303-338.
- [35] GOODFELLOW I, BENGIO Y, COURVILLE A. Deep learning [M]. Massachusetts: MIT Press, 2016.
- [36] LIU M, SHI J, LI Z, et al. Towards better analysis of deep convolutional neural networks [J]. IEEE Transactions on Visualization and Computer Graphics, 2016, 23 (1): 233-245.
- [37] HUSAIN S S, ONG E J, BOBER M. ACTNET: End-to-end learning of feature activations and multi-stream aggregation for effective instance image retrieval [J]. International Journal of Computer Vision, 2021, 129 (5): 1432-1450.
- [38] SHIN H C, ROTH H R, GAO M, et al. Deep convolutional neural networks for computer-aided detection: CNN architectures, dataset characteristics and transfer learning [J]. IEEE Transactions on Medical Imaging, 2016, 35 (5): 1285-1298.
- [39] ZHAO Z Q, ZHENG P, XU S T, et al. Object detection with deep learning: A review [J]. IEEE Transactions on Neural Networks and Learning Systems, 2019, 30 (11): 3212-3232.
- [40] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition [J]. Proceedings of the IEEE, 1998, 86 (3): 2278-2324.
- [41] ZEILER M D, FERGUS R. Visualizing and understanding convolutional networks [C] // ECCV. 2014 European Conference on Computer Vision. Zurich: Springer, 2014: 818-833.
- [42] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition [EB/OL]. (2014-09-04) [2015-04-10]. <https://arxiv.org/pdf/1409.1556.pdf>.
- [43] SZEGEDY C, WEI L, YANG Q J, et al. Going deeper with convolutions [C] // IEEE. 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2015: 1-9.
- [44] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition [C] // IEEE. 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2016: 770-778.
- [45] HUANG G, LIU Z, MAATEN L V, et al. Densely connected convolutional networks [C] // IEEE. 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2017: 2261-2269.
- [46] TAN M, LE Q V. EfficientNet: Rethinking model scaling

- for convolutional neural networks [C] // IMLS. Proceedings of the 36th International Conference on Machine Learning (ICML). Long Beach: IMLS, 2019, 6105-6114.
- [47] ZHANG X, ZHOU X, LIN M, et al. ShuffleNet: An extremely efficient convolutional neural network for mobile devices [C] // IEEE. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. New York: IEEE, 2018: 6848-6856.
- [48] HAN K, WANG Y, TIAN Q, et al. GhostNet: More features from cheap operations [C] // IEEE. 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2020, 1580-1589.
- [49] ZHANG L, YANG F, ZHANG Y D, et al. Road crack detection using deep convolutional neural network [C] // IEEE. 2016 IEEE International Conference on Image Processing (ICIP). New York: IEEE, 2016: 3708-3712.
- [50] GOPALAKRISHNAN K, KHATAN S K, CHOUDHARY A, et al. Deep convolutional neural networks with transfer learning for computer vision-based data-driven pavement distress detection [J]. Construction and Building Materials, 2017, 157 (1): 322-330.
- [51] SILVA W, SCHWERZ D. Concrete cracks detection based on deep learning image classification [J]. Proceedings, 2018, 9 (2): 489-495.
- [52] XU H, SU X, WANG Y, et al. Automatic bridge crack detection using a convolutional neural network [J]. Applied Sciences, 2019, 9 (14): 2867-2878.
- [53] FUENTES R. Deeper networks for pavement crack detection [C] // IAARC. Proceedings of the 34th International Symposium on Automation and Robotics in Construction (ISARC). Taipei: IAARC, 2017: 479-485.
- [54] WANG K C, ZHANG A, LI J Q, et al. Deep learning for asphalt pavement cracking recognition using convolutional neural network [J]. Airfield and Highway Pavements, 2017, 12 (3): 166-177.
- [55] EISENBACH M, STRICKER R, SEICHTER D, et al. How to get pavement distress detection ready for deep learning? A systematic approach [C] // IEEE. 2017 International Joint Conference on Neural Networks (IJCNN). New York: IEEE, 2017: 2161-4407.
- [56] SCHMUGGE S J, RICE L, NGUYEN N R, et al. Detection of cracks in nuclear power plant using spatial-temporal grouping of local patches [C] // IEEE. 2016 IEEE Winter Conference on Applications of Computer Vision (WACV). New York: IEEE, 2016: 1-7.
- [57] CHA Y J, CHOI W, BÜYÜKÖZTÜRK O. Deep learning-based crack damage detection using convolutional neural networks [J]. Computer-aided Civil and Infrastructure Engineering, 2017, 32 (5): 361-378.
- [58] CHEN F C, JAHANSIABI M. NB-CNN: Deep learning-based crack detection using convolutional neural network and naïve bayes data fusion [J]. IEEE Transactions on Industrial Electronics, 2017, 65 (5): 4392-4400.
- [59] LI S, ZHAO X. Image-based concrete crack detection using convolutional neural network and exhaustive search technique [J]. Advances in Civil Engineering, 2019, 12 (1): 1-12.
- [60] RAJADURAI R S, KANG S T. Automated vision-based crack detection on concrete surfaces using deep learning [J]. Applied Sciences, 2021, 11 (11): 5229.
- [61] 王丽萍,高瑞贞,张京军,等.基于卷积神经网络的混凝土路面裂缝检测[J].计算机科学,2019,46(增2):584-589.
- WANG Li-ping, GAO Rui-zhen, ZHANG Jing-jun, et al. Crack detection of concrete pavement based on convolutional neural network [J]. Computer Science, 2019, 46 (S2): 584-589.
- [62] TANG W, ZHAO Q, HUANG S, et al. Iteratively optimized patch label inference network for automatic pavement disease detection [EB/OL]. (2020-05-27) [2021-04-01]. <https://arxiv.org/pdf/2005.13298.pdf>.
- [63] XIE S, GIRSHICK R, DOLLÁR P, et al. Aggregated residual transformations for deep neural networks [C] // IEEE. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2017: 1492-1500.
- [64] BOCHKOVSKIY A, WANG C Y, LIAO H Y. YOLOv4: Optimal speed and accuracy of object detection [EB/OL]. (2020-04-23) [2021-11-16]. <https://arxiv.org/pdf/2004.10934.pdf>.
- [65] ZHAO N Y, JIANG Y, SONG Y. Recognition and classification of concrete cracks under strong interference based on convolutional neural network [J]. Traitement Du Signal, 2021, 38 (3): 911-917.
- [66] LI B, WANG K C, ZHANG A, et al. Automatic classification of pavement crack using deep convolutional neural network [J]. International Journal of Pavement Engineering, 2020, 21 (4): 457-463.
- [67] CHEN K, YADAV A, IF A, et al. Improved crack detection and recognition based on convolutional neural network [J]. Modelling and Simulation in Engineering, 2019, 1 (3): 1-8.
- [68] GAO Y, MOSALAM K M. Deep transfer learning for image-based structural damage recognition [J]. Computer-aided Civil and Infrastructure Engineering, 2018, 33 (9): 748-768.
- [69] 高尚兵,颉 正,潘志庚,等.一种新的路面裂缝自动检测算法 [J].系统仿真学报,2017,29(9):2009-2015.
- GAO Shang-bing, XIE Zheng, PAN Zhi-geng, et al. Novel automatic pavement crack detection algorithm [J]. Journal of System Simulation, 2017, 29 (9): 2009-2015.
- [70] GOPALAKRISHNAN K, GHOLAMI H, VIDYADHARAN A, et al. Crack damage detection in unmanned aerial vehicle images of civil infrastructure using pre-trained deep learning model [J]. International Journal for Traffic and Transport Engineering, 2018, 8 (2): 1-14.
- [71] JIANG Y, PANG D, LI C. A deep learning approach for fast detection and classification of concrete damage [J]. Automa-

- tion in Construction, 2021, 128: 103785.
- [72] CHA Y J, CHOI W, SUH G, et al. Autonomous structural visual inspection using region-based deep learning for detecting multiple damage types [J]. Computer-aided Civil and Infrastructure Engineering, 2018, 33 (9): 731-747.
- [73] 廖延娜, 李婉. 基于卷积神经网络的桥梁裂缝检测方法[J]. 计算机工程与设计, 2021, 42(8): 2366-2372.
- LIAO Yan-na, LI Wan. Bridge crack detection method based on convolution neural network [J]. Computer Engineering and Design, 2021, 42 (8): 2366-2372.
- [74] ZHANG C, CHANG C C, JAMSHIDI M. Bridge damage detection using a single-stage detector and field inspection images [EB/OL]. (2018-12-19) [2019-02-23]. <https://arxiv.org/pdf/1812.10590.pdf>.
- [75] MAEDA H, SEKIMOTO Y, SETO T, et al. Road damage detection and classification using deep neural networks with smartphone images [J]. Computer-aided Civil and Infrastructure Engineering, 2018, 33 (12): 1127-1141.
- [76] MANDAL V, UONG L, ADU-GYAMFI Y. Automated road crack detection using deep convolutional neural networks [C] // IEEE. 2018 IEEE International Conference on Big Data. New York: IEEE, 2018: 5212-5215.
- [77] NIE M, WANG K. Pavement distress detection based on transfer learning [C] // IEEE. 2018 5th International Conference on Systems and Informatics (ICSAI). New York: IEEE, 2018: 435-439.
- [78] XUE Y, LI Y. A fast detection method via region-based fully convolutional neural networks for shield tunnel lining defects [J]. Computer-aided Civil and Infrastructure Engineering, 2018, 33 (8): 638-654.
- [79] DENG L, CHU H H, SHI P, et al. Region-based CNN method with deformable modules for visually classifying concrete cracks [J]. Applied Sciences, 2020, 10 (7): 2528-2546.
- [80] ZOU Q, ZHANG Z, LI Q, et al. Deep Crack: Learning hierarchical convolutional features for crack detection [J]. IEEE Transactions on Image Processing, 2019, 28 (3): 1498-1512.
- [81] LI Z, ZHU H, HUANG M. A deep learning-based fine crack segmentation network on full-scale steel bridge images with complicated backgrounds [J]. IEEE Access, 2021, 9: 114989-114997.
- [82] 祝一帆, 王海涛, 李可, 等. 一种高精度路面裂缝检测网络结构: CrackU-Net[J]. 计算机科学, 2021, 48(8): 1-10.
- ZHU Yi-fan, WANG Hai-tao, LI Ke, et al. Crack U-Net: Towards high quality pavement crack detection [J]. Computer Science, 2021, 48 (8): 1-10.
- [83] DONG C Z, LI L D, YAN J, et al. Pixel-level fatigue crack segmentation in large-scale images of steel structures using an encoder-decoder network [J]. Sensors, 2021, 21 (12): 4135.
- [84] YANG X, LI H, YU Y, et al. Automatic pixel-level crack detection and measurement using fully convolutional network [J]. Computer-aided Civil and Infrastructure Engineering, 2018, 33 (12): 1090-1109.
- [85] LI Z H, ZHU H M, HUANG M Q. A deep learning-based fine crack segmentation network on full-scale steel bridge images with complicated backgrounds [J]. IEEE Access, 2021, 9: 114989-114997.
- [86] LIU Y, YAO J, LU X, et al. Deep Crack: A deep hierarchical feature learning architecture for crack segmentation [J]. Neurocomputing, 2019, 338 (1): 139-153.
- [87] CARR T A, JENKINS M D, IGLESIAS M I, et al. Road crack detection using a single stage detector based deep neural network [C] // IEEE. 2018 IEEE Workshop on Environmental, Energy, and Structural Monitoring Systems (EEMS). New York: IEEE, 2018: 1-5.
- [88] WANG S, PAN Y, CHEN M, et al. FCN-SFW: Steel structure crack segmentation using a fully convolutional network and structured forests [J]. IEEE Access, 2020, 8: 214358-214373.
- [89] JENKINS M D, CARR T A, IGLESIAS M I, et al. A deep convolutional neural network for semantic pixel-wise segmentation of road and pavement surface cracks [C] // IEEE. 2018 26th European Signal Processing Conference (EUSIPCO). New York: IEEE, 2018: 2120-2124.
- [90] TABERNIK D, ŠELA S, SKVARČ J, et al. Segmentation-based deep-learning approach for surface-defect detection [J]. Journal of Intelligent Manufacturing, 2020, 31 (3): 759-776.
- [91] ZHANG K, ZHANG Y, CHENG H D. Self-supervised structure learning for crack detection based on cycle-consistent generative adversarial networks [J]. Journal of Computing in Civil Engineering, 2020, 34 (3): 04020004.
- [92] ALIPOUR M, HARRIS D K, MILLER G R. Robust pixel-level crack detection using deep fully convolutional neural networks [J]. Journal of Computing in Civil Engineering, 2019, 33 (6): 04019040.
- [93] YANG F, ZHANG L, YU S, et al. Feature pyramid and hierarchical boosting network for pavement crack detection [J]. IEEE Transactions on Intelligent Transportation Systems, 2019, 21 (4): 1525-1535.
- [94] FAN Z, LI C, CHEN Y, et al. Automatic crack detection on road pavements using encoder-decoder architecture [J]. Materials, 2020, 13 (13): 2960-2974.
- [95] FAN Z, LI C, CHEN Y, et al. Ensemble of deep convolutional neural networks for automatic pavement crack detection and measurement [J]. Coatings, 2020, 10 (2): 152.
- [96] KÖNIG J, JENKINS M, MANNION M, et al. Optimized deep encoder-decoder methods for crack segmentation [J]. Digital Signal Processing, 2021, 108: 102907.
- [97] LIU W, HUANG Y, LI Y, et al. FPCNet: Fast pavement crack detection network based on encoder-decoder architecture [EB/OL]. (2019-07-04) [2021-11-16]. <https://arxiv.org/pdf/1907.04161.pdf>.

- org/pdf/1907.02248.pdf.
- [98] FEI Y, WANG K C, ZHANG A, et al. Pixel-level cracking detection on 3D asphalt pavement images through deep-learning-based cracknet-V [J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 21 (1): 273-284.
- [99] KALFARISI R, WU Z Y, SOH K. Crack detection and segmentation using deep learning with 3D reality mesh model for quantitative assessment and integrated visualization [J]. Journal of Computing in Civil Engineering, 2020, 34 (3): 04020010.
- [100] 郎 洪,温 添,陆 键,等.基于深度学习的三维路面裂缝类病害检测方法[J].东南大学学报(自然科学版),2021,51(1): 53-60.
- LANG Hong, WEN Tian, LU Jian, et al. 3D pavement crack detection method based on deep learning [J]. Journal of Southeast University (Natural Science Edition), 2021, 51 (1): 53-60.
- [101] ZHANG A, WANG K C, FEI Y, et al. Automated pixel-level pavement crack detection on 3D asphalt surfaces with a recurrent neural network [J]. Computer-aided Civil and Infrastructure Engineering, 2019, 34 (3): 213-229.
- [102] SAJEDI S O, LIANG X. A convolutional cost-sensitive crack localization algorithm for automated and reliable RC bridge inspection [M]. Boca Raton: CRC Press, 2019.
- [103] CHENG C, SHANG Z, SHEN Z. Automatic delamination segmentation for bridge deck based on encoder-decoder deep learning through UAV-based thermography [J]. NDT & E International, 2020, 116 (1): 102341.
- [104] 孙乐乐,孙 恒,徐 婷.基于无人机的桥梁三维重构及检测系统[C]//第十四届中国智能交通年会学术委员会.第十四届中国智能交通年会论文集.北京:电子工业出版社,2019: 345-357.
- SUN Le-le, SUN Heng, XU Ting. Bridge 3D reconstruction and detection system based on UAV [C] // Academic Committee of the 14th China Intelligent Transportation Annual Conference. Proceedings of the 14th China Intelligent Transportation Conference. Beijing: Electronic Industry Press, 2019: 345-357.
- [105] HAN K, WANG Y, CHEN H, et al. A survey on visual transformer [EB/OL]. (2020-12-23) [2021-08-12]. <https://arxiv.org/pdf/2012.12556.pdf>.
- [106] KHAN S, NASEER M, HAYAT M, et al. Transformers in vision: A survey [EB/OL]. (2021-01-04) [2021-10-03]. <https://arxiv.org/pdf/2101.01169.pdf>.
- [107] CHEN M, RADFORD A, CHILD R. Generative pretraining from pixels [C] // BACH F, BLEI D, SCHÖLKOPF B. Proceedings of 37th International Conference on Machine Learning Research (PMLR). Gandy: Microtome Publishing, 2020: 1691-1703.
- [108] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16×16 words: Transformers for image recognition at scale [EB/OL]. (2020-10-22) [2021-06-03]. <https://arxiv.org/pdf/2010.11929.pdf>.
- [109] CARION N, MASSA F, SYNNAEVE G, et al. End-to-end object detection with transformers [EB/OL]. (2020-05-26) [2020-05-28]. <https://arxiv.org/pdf/2005.12872.pdf>.
- [110] ZHU X, SU W, LU L, et al. Deformable DETR: Deformable transformers for end-to-end object detection [EB/OL]. (2020-10-08) [2021-03-18]. <https://arxiv.org/pdf/2010.04159.pdf>.
- [111] ZHENG M, GAO P, WANG X, et al. End-to-end object detection with adaptive clustering transformer [EB/OL]. (2020-12-23) [2020-10-12]. <https://arxiv.org/pdf/2012.12556.pdf>.
- [112] WANG H, ZHU Y, ADAM H, et al. Max-deeplab: End-to-end panoptic segmentation with mask transformers [EB/OL]. (2020-12-01) [2021-07-12]. <https://arxiv.org/pdf/2012.00759.pdf>.
- [113] WANG Y, XU Z, WANG X, et al. End-to-end video instance segmentation with transformers [EB/OL]. (2020-11-30) [2021-10-08]. <https://arxiv.org/pdf/2011.14503.pdf>.
- [114] ZHENG S, LU J, ZHAO H, et al. Rethinking semantic segmentation from a sequence-to-sequence perspective with transformers [EB/OL]. (2020-12-31) [2021-07-25]. <https://arxiv.org/pdf/2012.15840.pdf>.
- [115] LIU H, MIAO X, MERTZ C, et al. Crack Former: Transformer network for fine-grained crack detection [C] // IEEE. Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). New York: IEEE, 2021: 3783-3792.
- [116] GUO J M, MARKONI H. Transformer based refinement network for accurate crack detection [C] // IEEE. 2021 International Conference on System Science and Engineering (ICSSE). New York: IEEE, 2021: 442-446.
- [117] XU Y, WEI S, BAO Y, et al. Automatic seismic damage identification of reinforced concrete columns from images by a region-based deep convolutional neural network [J]. Structural Control and Health Monitoring, 2019, 26 (3): 2313.
- [118] WANG N, ZHAO Q, LI S, et al. Damage classification for masonry historic structures using convolutional neural networks based on still images [J]. Computer-aided Civil and Infrastructure Engineering, 2018, 33 (12): 1073-1089.
- [119] MODARRES C, ASTORGA N, DROGUETT E L, et al. Convolutional neural networks for automated damage recognition and damage type identification [J]. Structural Control and Health Monitoring, 2018, 25 (10): 2230.
- [120] YE X W, JIN T, CHEN P Y. Structural crack detection using deep learning-based fully convolutional networks [J]. Advances in Structural Engineering, 2019, 22 (16): 3412-3419.
- [121] DUNG C V, SEKIYA H, HIRANO S, et al. A vision-based method for crack detection in gusset plate welded joints of steel bridges using deep convolutional neural networks [J]. Automation in Construction, 2019, 102 (1): 217-229.

- [122] LI Y, ZHAO W, ZHANG X, et al. A two-stage crack detection method for concrete bridges using convolutional neural networks [J]. IEICE Transactions on Information and Systems, 2018, 101 (12): 3249-3252.
- [123] JANG K, KIM N, AN Y K. Deep learning-based autonomous concrete crack evaluation through hybrid image scanning [J]. Structural Health Monitoring, 2019, 18 (5/6): 1722-1737.
- [124] TSAI Y J, LI F. Critical assessment of detecting asphalt pavement cracks under different lighting and low intensity contrast conditions using emerging 3D laser technology [J]. Journal of Transportation Engineering, 2012, 138 (5): 649-656.
- [125] SHI Y, CUI L, QI Z, et al. Automatic road crack detection using random structured forests [J]. IEEE Transactions on Intelligent Transportation Systems, 2016, 17 (12): 3434-3445.
- [126] AMHAZ R, CHAMBON S, IDIER J, et al. Automatic crack detection on two-dimensional pavement images: An algorithm based on minimal path selection [J]. IEEE Transactions on Intelligent Transportation Systems, 2016, 17 (10): 2718-2729.
- [127] ZOU Q, CAO Y, LI Q, et al. Crack Tree: Automatic crack detection from pavement images [J]. Pattern Recognition Letters, 2012, 33 (3): 227-238.
- [128] ZHOU S, SONG W. Deep learning-based roadway crack classification using laser-scanned range images: A comparative study on hyperparameter selection [J]. Automation in Construction, 2020, 114 (1): 103171.
- [129] DORAFSHAN S, THOMAS R, MAGUIRE M. SDNET2018: An annotated image dataset for non-contact concrete crack detection using deep convolutional neural networks [J]. Data in Brief, 2018, 21 (1): 1664-1668.
- [130] CIREŞAN D, GIUSTI A, GAMBARDELLA L M, et al. Mitosis detection in breast cancer histology images with deep neural networks [C] // MICCAI. The 16th International Conference on Medical Image Computing and Computer-assisted Intervention (MICCAI). Nagoya: Springer, 2013: 411-418.
- [131] SALTON G, MCGILL M J. Introduction to modern information retrieval [M]. New York: McGraw-hill, 1986.
- [132] TSAI Y C, CHATTERJEE A. Comprehensive, quantitative crack detection algorithm performance evaluation system [J]. Journal of Computing in Civil Engineering, 2017, 31 (5): 04017047.
- [133] LI H, WANG J, ZHANG Y, et al. A study on evaluation standard for automatic crack detection regard the random fractal [EB/OL]. (2020-07-23) [2021-11-16]. <https://arxiv.org/pdf/2007.12082.pdf>.
- [134] CHO H T, JUNG S. Implementation and control of crack tracking robot using force control; Crack detection by laser and camera sensor using neural network [J]. Journal of Institute of Control, Robotics and Systems, 2005, 11 (4): 290-296.
- [135] ANAND S, GUPTA S, DARBAVI V, et al. Crack-pot: Autonomous road crack and pothole detection [C] // IEEE. 2018 Digital Image Computing: Techniques and Applications (DICTA). New York: IEEE, 2018: 1-6.
- [136] RAMALINGAM B, HAYAT A A, ELARA M R, et al. Deep learning based pavement inspection using self-reconfigurable robot [J]. Sensors, 2021, 21 (8): 2595.
- [137] ZHU G, FAN Z, CHEN W, et al. Design and implementation of a manipulator system for roadway crack sealing [C] // IEEE. 9th Annual International Conference on CYBER Technology in Automation, Control, and Intelligent Systems (CYBER). New York: IEEE, 2019: 1327-1331.
- [138] PAN Y, ZHANG X, CERVONE G, et al. Detection of asphalt pavement potholes and cracks based on the unmanned aerial vehicle multispectral imagery [J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2018, 11 (10): 3701-3712.
- [139] LA H M, GUCUNSKI N, KEE S H, et al. Autonomous robotic system for bridge deck data collection and analysis [C] // IEEE. 2014 IEEE/RSJ International Conference on Intelligent Robots and Systems. New York: IEEE, 2014: 1950-1955.
- [140] LEIBBRANDT A, CAPRARI G, ANGST U, et al. Climbing robot for corrosion monitoring of reinforced concrete structures [C] // IEEE. 2012 2nd International Conference on Applied Robotics for the Power Industry (CARPI). New York: IEEE, 2012: 10-15.
- [141] GUAN D, YAN L, YANG Y, et al. A small climbing robot for the intelligent inspection of nuclear power plants [C] // IEEE. 2014 4th IEEE International Conference on Information Science and Technology. New York: IEEE, 2014: 484-487.
- [142] JUNG S, SONG S, KIM S, et al. Toward autonomous bridge inspection: A framework and experimental results [C] // IEEE. 2019 16th International Conference on Ubiquitous Robots (UR). New York: IEEE, 2019: 208-211.
- [143] LIU Q, LIU Y. An approach for auto bridge inspection based on climbing robot [C] // IEEE. 2013 IEEE International Conference on Robotics and Biomimetics (ROBIO). New York: IEEE, 2013: 2581-2586.
- [144] JANG K, AN Y K, KIM B, et al. Automated crack evaluation of a high-rise bridge pier using a ring-type climbing robot [J]. Computer-aided Civil and Infrastructure Engineering, 2021, 36 (1): 14-29.
- [145] XIE R, YAO J, LIU K, et al. Automatic multi-image stitching for concrete bridge inspection by combining point and line features [J]. Automation in Construction, 2018, 90: 265-280.
- [146] HE Z L, JIANG S, ZHANG J. Automatic damage detection using anchor-free method and unmanned surface vessel [J].

- Automation in Construction, 2022, 133: 104017.
- [147] MURPHY R R, STEIMLE E, HALL M, et al. Robot-assisted bridge inspection [J]. Journal of Intelligent & Robotic Systems, 2011, 64 (1): 77-95.
- [148] ELLENBERG A, KONTSOS A, MOON F, et al. Bridge deck delamination identification from unmanned aerial vehicle infrared imagery [J]. Automation in Construction, 2016, 72: 155-165.
- [149] SEO J, DUQUE L, WACKER J. Drone-enabled bridge inspection methodology and application [J]. Automation in Construction, 2018, 94: 112-126.
- [150] RATSAMEE P, KRIENGKOMOL P, ARAI T, et al. A hybrid flying and walking robot for steel bridge inspection [C] // IEEE. 2016 IEEE International Symposium on Safety, Security, and Rescue Robotics (SSRR). New York: IEEE, 2016: 62-67.
- [151] MYEONG W, MYUNG H. Development of a wall-climbing drone capable of vertical soft landing using a tilt-rotor mechanism [J]. IEEE Access, 2018, 7: 4868-4879.
- [152] YU S N, JANG J H, HAN C S. Auto inspection system using a mobile robot for detecting concrete cracks in a tunnel [J]. Automation in Construction, 2007, 16 (3): 255-61.
- [153] PROTOPAPADAKIS E, VOULODIMOS A, DOULAMIS A, et al. Automatic crack detection for tunnel inspection using deep learning and heuristic image post-processing [J]. Applied Intelligence, 2019, 49 (7): 2793-2806.
- [154] LEONIDAS E, XU Y. The development of an automatic inspection system used for the maintenance of rail tunnels [C] // IEEE. 2018 24th International Conference on Automation and Computing (ICAC). New York: IEEE, 2018: 1-6.
- [155] 王平让,黄宏伟,薛亚东.隧道衬砌裂缝自动检测性能影响因素模型试验研究[J].岩石力学与工程学报,2012,31(8):1705-1714.
WANG Ping-rang, HUANG Hong-wei, XUE Ya-dong. Model test study of factors affecting automatic detection performance of cracks in tunnel lining [J]. Chinese Journal of Rock Mechanics and Engineering, 2012, 31 (8): 1705-1714.
- [156] HUANG H W, YAN S, XUE Y, et al. Inspection equipment study for subway tunnel defects by grey-scale image processing [J]. Advanced Engineering Informatics, 2017, 32: 188-201.
- [157] YAN R J, KAYACAN E, CHEN I M, et al. A novel building post-construction quality assessment robot: Design and prototyping [C] // IEEE. 2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). New York: IEEE, 2017: 6020-6030.
- [158] YAN R J, KAYACAN E, CHEN I M, et al. QuicaBot: Quality inspection and assessment robot [J]. IEEE Transactions on Automation Science and Engineering, 2018, 16 (2): 506-517.
- [159] CHOI S S, KIM E K. Building crack inspection using small UAV [C] // IEEE. Proceedings of 2015 International Conference on Advanced Communication Technology. New York: IEEE, 2019: 235-238.
- [160] DE PAZ J Z, CASTAÑEDA E C, CASTRO X S, et al. Crack detection by a climbing robot using image analysis [C] // IEEE. Conference Crack Detection by a Climbing Robot Using Image Analysis. New York: IEEE, 2013: 87-91.
- [161] KOUZEHGAR M, TAMILSELVAM Y K, HEREDIA M V, et al. Self-reconfigurable facade-cleaning robot equipped with deep-learning-based crack detection based on convolutional neural networks [J]. Automation in Construction, 2019, 108: 1-11.
- [162] TOROK M M, GOLPARVAR-FARD M, KOCHERSBERGER K B. Image-based automated 3D crack detection for post-disaster building assessment [J]. Journal of Computing in Civil Engineering, 2015, 28 (5): A4014004.
- [163] HOSSIN M, MUSTAPHA A, MUSTAPHA N, et al. A hybrid evaluation metric for optimizing classifier [C] // IEEE. 2011 3rd Conference on Data Mining and Optimization (DMO). New York: IEEE, 2011: 165-170.